

UNIVERSIDADE DE BRASÍLIA
FACULDADE DE TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA

ANÁLISE DO DISCURSO PARLAMENTAR POR MEIO DA
TÉCNICA DO PROCESSAMENTO DE LINGUAGEM
NATURAL: ABORDAGEM ESTATÍSTICA E
APRENDIZAGEM DE MÁQUINA

FABIANO PERUZZO SCHWARTZ

SUPERVISOR: FRANCISCO ASSIS DE OLIVEIRA NASCIMENTO

RELATÓRIO DE PESQUISA DE ESTÁGIO PÓS-DOCTORAL

BRASÍLIA/DF: FEVEREIRO – 2018.

UNIVERSIDADE DE BRASÍLIA
FACULDADE DE TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA

**“ANÁLISE DO DISCURSO PARLAMENTAR POR MEIO DA
TÉCNICA DO PROCESSAMENTO DE LINGUAGEM NATURAL:
ABORDAGEM ESTATÍSTICA E APRENDIZAGEM DE MÁQUINA”**

FABIANO PERUZZO SCHWARTZ

**RELATÓRIO DE PESQUISA APRESENTADO COMO REQUISITO DE
CONCLUSÃO DE ESTÁGIO PÓS-DOCTORAL REALIZADO NO
DEPARTAMENTO DE ENGENHARIA DA UNIVERSIDADE DE BRASÍLIA, NO
PERÍODO DE 01/03/2017 A 28/02/2018.**

APROVADO POR:



**Francisco Assis de Oliveira Nascimento, Dr. – Professor Titular
Coordenador do Grupo de Processamento Digital de Sinais – GPDS
Departamento de Engenharia Elétrica – ENE
Faculdade de Tecnologia – FT
Universidade de Brasília – UnB**

BRASÍLIA, 28 DE FEVEREIRO DE 2018.

FICHA CATALOGRÁFICA

SCHWARTZ, FABIANO PERUZZO

Análise do discurso parlamentar por meio da técnica do processamento de linguagem natural: abordagem estatística e aprendizagem de máquina [Distrito Federal] 2018.

xiii, 82p., 210 x 297 mm (ENE/FT/UnB, Estágio Pós-Doutoral, Engenharia de Sistemas Eletrônicos e de Automação, 2018).

Relatório de Pesquisa – Universidade de Brasília. Faculdade de Tecnologia.

Departamento de Engenharia Elétrica.

1. Discurso Parlamentar

2. Processamento de Linguagem Natural

3. Estatística

4. Aprendizagem de Máquina

I. ENE/FT/UNB

II. Título (série)

REFERÊNCIA BIBLIOGRÁFICA

SCHWARTZ, F. P. (2018). Análise do discurso parlamentar por meio da técnica do processamento de linguagem natural: abordagem estatística e aprendizagem de máquina. Relatório de Pesquisa de Estágio Pós-Doutoral, Departamento de Engenharia Elétrica, Universidade de Brasília, Brasília, DF, 82p.

CESSÃO DE DIREITOS

AUTOR: Fabiano Peruzzo Schwartz

TÍTULO: Análise do discurso parlamentar por meio da técnica do processamento de linguagem natural: abordagem estatística e aprendizagem de máquina.

GRAU: Doutor

ANO: 2018

É concedida à Universidade de Brasília permissão para reproduzir cópias deste relatório de pesquisa e para emprestar ou vender tais cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte deste relatório pode ser reproduzida sem autorização por escrito do autor.

Fabiano Peruzzo Schwartz

SHDB QL 32, Conjunto 07, Casa 55-B.

71.676-135 Brasília – DF - Brasil.

DEDICATÓRIA

À minha esposa Flávia, ao meu filho Diogo, aos meus pais, José e Nina,
meus sogro e sogra, Agostinho e Maristella, e ao amigo Alfredo.

“A arte da vida está na habilidade de vivermos o máximo que pudermos, com alegria.
Lutemos pela vida até o último segundo. Após a morte, aceitemos a morte.”

Alfredo José Procaci Ferreira

AGRADECIMENTOS

Agradeço, primeiramente, ao professor Francisco Assis de Oliveira Nascimento, grande sujeito e supervisor desta pesquisa, por mais esta oportunidade, pela troca de ideias, pela abertura a novas propostas, por incentivar o pensamento livre para a ciência.

À minha esposa e filho, por estarem sempre ao meu lado, por sermos uma família, por darem sentido à minha vida. A Flávia executou o árduo trabalho de organizar as referências bibliográficas deste relatório no formato ABNT, tarefa que viabilizou a entrega em tempo.

À Câmara dos Deputados, por dar suporte e incentivo ao aperfeiçoamento dos seus servidores e por tantas oportunidades de trabalho e experiências, condições que somente se encontram em instituições que prezam pela excelência.

À Universidade de Brasília, instituição que respeito profundamente e que me acolheu desde os tempos da graduação, do mestrado, do doutorado e, agora, nesta jornada de estágio pós-doutoral.

RESUMO

ANÁLISE DO DISCURSO PARLAMENTAR POR MEIO DA TÉCNICA DO PROCESSAMENTO DE LINGUAGEM NATURAL: ABORDAGEM ESTATÍSTICA E APRENDIZAGEM DE MÁQUINA

Autor: Fabiano Peruzzo Schwartz

Supervisor: Francisco Assis de Oliveira Nascimento

**Programa de Pós-Graduação em Engenharia de Sistemas Eletrônicos e de Automação
Brasília, fevereiro de 2018**

A presente pesquisa consiste na sistematização da informação contida nos dados não-estruturados do discurso parlamentar por meio da aplicação da técnica do Processamento de Linguagem Natural (PLN), a fim de resgatar aspectos qualitativos do discurso e de estabelecer as conexões entre fatos, dados quantitativos e resultados finais da atividade legislativa. Trata-se não somente da investigação de vocábulos e expressões do texto, mas, também, da extração de sentido e/ou de padrões do discurso parlamentar no contexto temporal. Modelos estatísticos e de aprendizagem de máquina foram testados e avaliados como potenciais ferramentas de análise do discurso.

Como principais contribuições podem ser destacadas: (1) a estruturação de base textual dos discursos parlamentares compreendendo as legislaturas de número 51 a 55, (2) a definição do Índice de Identidade Ideológica, que constitui ferramenta objetiva de análise do discurso parlamentar e pode ser usada como parâmetro de comparação entre estudos, e (3) a disponibilização dos dados, scripts de programação e resultados em repositório público, com a finalidade de incentivar novos estudos sobre o tema e de prover meios para a reprodutibilidade da pesquisa.

ABSTRACT

ANALYSIS OF PARLIAMENTARY SPEECH BY THE TECHNIQUE OF NATURAL LANGUAGE PROCESSING: STATISTICAL APPROACH AND MACHINE LEARNING

Author: Fabiano Peruzzo Schwartz

Supervisor: Francisco Assis de Oliveira Nascimento

**Programa de Pós-Graduação em Engenharia de Sistemas Eletrônicos e de Automação
Brasília, February of 2018**

This research consists in the systematization of information contained in unstructured data of parliamentary speech through the application of Natural Language Processing technique so as to rescue qualitative aspects of speech and establish connections between facts, figures and final results of legislative activity. It is not only the investigation of words and expressions of the text, but also a way of extracting meaning and/or patterns of parliamentary discourse in the temporal context. Statistical and machine learning models were tested and evaluated as potential discourse analysis tools.

Main contributions can be highlighted: (1) the structuring of textual basis of parliamentary speeches comprising the legislatures 51 to 55, (2) the definition of Ideological Identity Index, which is an objective tool of analysis of parliamentary discourse and can be used as a benchmark among studies, and (3) the availability of data, programming scripts and results in public repository in order to encourage new studies on the subject and to provide means for the reproducibility of research.

SUMÁRIO

LISTA DE TABELAS.....	X
LISTA DE QUADROS.....	XI
LISTA DE FIGURAS.....	XII
LISTA DE ABREVIACÕES	XIII
1 INTRODUÇÃO.....	1
2 DISCURSO PARLAMENTAR E O PROCESSAMENTO DE LINGUAGEM NATURAL.....	4
3 ESTRUTURAÇÃO DE CORPORA	11
3.1 LEITURA DOS DADOS	11
3.2 LIMPEZA PRELIMINAR DOS DADOS DE DISCURSO	15
4 EXTRAÇÃO DE INFORMAÇÕES DO TEXTO.....	17
4.1 DEFINIÇÃO DE CORPUS POR CRITÉRIOS DE ANÁLISE	17
4.2 PRÉ-PROCESSAMENTO DO CORPUS	18
4.3 TOKENIZAÇÃO.....	21
4.3.1 Frequência de termos relativa à frequência inversa de documentos (Term Frequency-Inverse Document Frequency).....	22
4.3.2 Ajuste de esparsidade da Matriz Termo Documento.....	23
4.3.3 Bigramas.....	23
4.4 PESQUISA EXPLORATÓRIA.....	24
4.4.1 Nuvens de palavras e gráficos de frequência	25
4.4.2 Classificadores: clusterização e modelo de tópicos.....	29
4.5 ANÁLISE.....	34
5 ABORDAGEM ESTATÍSTICA.....	37
5.1 HISTOGRAMA E DENSIDADE DE PROBABILIDADE.....	37

5.2	TESTE QUI-QUADRADO	43
5.2.1	Distribuição Qui-quadrado.....	44
5.2.2	Tabela de Contingência.....	46
5.3	COLLOCATIONS.....	48
5.4	SIMILARIDADE DE CORPUS.....	51
5.5	IDEOLOGIA POLÍTICO-PARTIDÁRIA E COALIZÃO	53
5.6	ÍNDICE DE IDENTIDADE IDEOLÓGICA	56
5.7	ANÁLISE.....	59
6	APRENDIZAGEM DE MÁQUINA.....	62
6.1	MÉTODO DE NAIVE BAYES	63
6.2	CLASSIFICAÇÃO DO DISCURSO PARLAMENTAR.....	64
6.2.1	Experimento de classificação	65
6.2.2	Experimento de similaridade com algoritmo Naive Bayes	67
7	CONCLUSÕES E RECOMENDAÇÕES.....	69
	REFERÊNCIAS BIBLIOGRÁFICAS	73
	ANEXO A – ATESTE DE ATIVIDADES - MARÇO/ABRIL DE 2017	78
	ANEXO B – ATESTE DE ATIVIDADES - MAIO/JUNHO DE 2017	79
	ANEXO C – ATESTE DE ATIVIDADES - JULHO/AGOSTO DE 2017	80
	ANEXO D – ATESTE DE ATIVIDADES - SETEMBRO/NOVEMBRO DE 2017....	81
	ANEXO E – ATESTE DE ATIVIDADES - DEZEMBRO DE 2017 A FEVEREIRO DE 2018	82

LISTA DE TABELAS

Tabela 5.1: Tabela de Contingência: pesquisa de opinião sobre preferência partidária classificada por sexo.....	47
Tabela 5.2: Tabela de Contingência e valores esperados: pesquisa de opinião sobre preferência partidária classificada por sexo.....	48
Tabela 5.3: Tabela de contingência: distribuição dos termos “ensino” e “médio” para análise do bigrama “ensino medio”.	49
Tabela 5.4: Teste qui-quadrado para a verificação de <i>collocations</i> nos 10 bigramas mais frequentes nos discursos do PT, no ano de 2016.	50
Tabela 5.5: Teste qui-quadrado para a verificação de <i>collocations</i> nos 10 bigramas mais frequentes nos discursos do PSDB, no ano de 2016.	50
Tabela 5.6: Palavras mais frequentes comuns aos <i>corpus</i> de discursos do PT e PSDB em 2016.	51
Tabela 5.7: Métrica χ^2 para similaridade de <i>corpus</i> : partidos PT, PSDB, PMDB, PSOL, PCdoB e PTB; ano 2016.....	52
Tabela 5.8: Matriz de similaridade do discurso para o ano de 2003: i_{coa} é o índice de identidade ideológica para a coalizão governista; i_{opo} é o índice de identidade ideológica para a oposição; i_{dif} é o índice de identidade ideológica quando grupos diferentes são comparados.....	57

LISTA DE QUADROS

Quadro 4.1: Resultado da aplicação dos métodos VEM e Gibbs para os discursos do PSDB no ano de 2016.....	32
Quadro 4.2: Resultado da aplicação dos métodos VEM e Gibbs para os discursos do PT no ano de 2016.....	33
Quadro 4.3: Tópicos levantados para os discursos do PT, no período de 2010 a 2017, por meio da identificação de unigramas e bigramas e da aplicação da LDA.	35
Quadro 4.4: Tópicos levantados para os discursos do PSDB, no período de 2010 a 2017, por meio da identificação de unigramas e bigramas e da aplicação da LDA.	36
Quadro 6.1: Estrutura do arquivo de discursos do PT e PSDB no período de 2001 a 2015.	65

LISTA DE FIGURAS

Figura 2.1: Roteiro clássico da mineração de textos (adaptado de Kwartler (2018)).	10
Figura 3.1: Página do serviço de acesso a dados das sessões plenárias.	12
Figura 3.2: Método ListarDiscursoPlenario: parâmetros de consulta e hierarquia dos dados retornados.	13
Figura 3.3: Método ObterInteiroTeorDiscursosPlenários: parâmetros de consulta e estrutura dos dados retornados.	14
Figura 4.1: Nuvem de palavras e gráfico de barras dos discursos do PSDB em 2016: (a) frequência absoluta; (b) tratamento TFIDF e ajuste de esparsidade.	26
Figura 4.2: Nuvem de palavras e gráfico de barras dos discursos do PT em 2016: (a) frequência absoluta; (b) tratamento TFIDF e ajuste de esparsidade.	27
Figura 4.3: Nuvem de palavras e gráfico de barras de frequências absolutas: (a) bigramas dos discursos do PSDB em 2016; (b) bigramas dos discursos do PT em 2016.	28
Figura 4.4: Dendogramas referentes à clusterização dos bigramas identificados nos discursos do ano de 2016: (a) PSDB; (b) PT.	30
Figura 5.1: Ocorrências do termo “corrupção” em cada discurso dos partidos PT e PSDB ao longo do ano de 2016.	38
Figura 5.2: Distribuição do tema “corrupção” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.	39
Figura 5.3: Distribuição do tema “educação” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.	40
Figura 5.4: Distribuição do tema “previdência” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.	41
Figura 5.5: Distribuição do tema “mulher” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.	42
Figura 5.6: Distribuição χ^2 para distintos valores de k .	45
Figura 5.7: Índice de Identidade Ideológica no período de 2001 a 2015.	58
Figura 6.1: Acurácia do modelo multinomial de Naive Bayes para a classificação do discurso parlamentar como PT ou PSDB, de acordo com a variação do hiperparâmetro α .	66
Figura 6.2: Acurácia de Naive Bayes ($\alpha = 8$) vs. estatística χ^2 : similaridade do discurso.	67

LISTA DE ABREVIACÕES

HTTP	Hypertext Transfer Protocol é o método utilizado para enviar e receber informações na web.
LDA	Latent Dirichlet Allocation
MIME	Multipurpose Internet Mail Extensions
MDT	Matriz Documento Termo
MTD	Matriz Termo Documento
PLN	Processamento de Linguagem Natural
RICD	Regimento Interno da Câmara dos Deputados
TFIDF	Term Frequency-Inverse Document Frequency
XML	(eXtensible Markup Language) é um formato para a criação de documentos com dados organizados de forma hierárquica, por meio de marcações específicas.
URL	Uniform Resource Locator
VEM	Variational Expectation Maximization

1 INTRODUÇÃO

O Poder Legislativo cumpre papel imprescindível perante a sociedade do País, visto que desempenha três funções primordiais para a consolidação da democracia: representar o povo brasileiro, legislar sobre os assuntos de interesse nacional e fiscalizar a aplicação dos recursos públicos.

Nesse contexto, a Câmara dos Deputados, autêntica representante do povo brasileiro, exerce atividades que viabilizam a realização dos anseios da população e é composta por deputados oriundos de todos os Estados e do Distrito Federal, o que resulta em um Parlamento com diversidade de ideias, revelando-se uma Casa legislativa plural, a serviço da sociedade brasileira.

Os trabalhos legislativos e a atividade parlamentar são regidos pelo Processo Legislativo¹ e estão intimamente atrelados ao diálogo. No Plenário, órgão máximo de deliberação da Câmara dos Deputados, os representantes do povo discutem e votam soberanamente as proposições em tramitação. A habilidade retórica de arranjar adequadamente as ideias, de colocar os argumentos apropriados, de organizar e apresentar oralmente o discurso para uma audiência é a principal ferramenta do parlamentar no exercício do seu ofício.

Dessa atividade brota o conhecimento que é próprio da atuação finalística do Poder Legislativo e que somente nesse contexto é produzido. Logo, é de fundamental importância para a continuidade do processo democrático que esse conhecimento esteja ao alcance da própria Instituição e da sociedade, de forma simples e precisa.

Dados protocolares do Processo Legislativo são tratados de forma estruturada e contam a parte da história restrita às fases previstas na regra. Contudo, os caminhos da discussão que levam à forma final do texto normativo ficam dispersos no registro taquigráfico dos discursos e debates, ou seja, em dado não-estruturado. Isso dificulta o resgate da linha argumentativa pró e contra determinado tema discutido no âmbito das sessões plenárias. Tal resgate, quando necessário, consiste em remontar, muitas vezes de forma manual, a

¹ Processo Legislativo é o conjunto de atos realizados pelos órgãos do Poder Legislativo, de acordo com regras previamente fixadas, para a elaboração de normas jurídicas, sejam emendas à Constituição, leis complementares, leis ordinárias e outros tipos normativos dispostos no art. 59 da Constituição Federal.

sequência dos fatos, memórias e aspectos comportamentais dos agentes envolvidos em determinado evento, com a finalidade de se compreender a lógica das decisões. Esse processo é, em geral, moroso e impreciso. A captação e gestão do conhecimento implícito no discurso parlamentar podem ser aprimoradas pelo uso de recursos computacionais e técnicas avançadas de processamento linguístico.

Nesse sentido, justifica-se o presente esforço de pesquisa que consiste na sistematização da informação contida nos dados não-estruturados do discurso parlamentar por meio da aplicação da técnica do Processamento de Linguagem Natural (PLN), a fim de resgatar aspectos qualitativos do discurso e a estabelecer as conexões entre fatos, dados quantitativos e resultados finais do Processo Legislativo. Não se trata apenas de encontrar vocábulos ou expressões no texto, mas de extrair sentido e/ou padrões do discurso parlamentar no contexto temporal.

O objetivo geral deste trabalho de pesquisa tem abordagem prática e se concentra no desenvolvimento e aplicação de algoritmos computacionais, baseados em PLN, estatística e aprendizagem de máquina, com a finalidade organizar, classificar, recuperar e divulgar o conhecimento implícito da atividade política contida no discurso parlamentar.

Como objetivos específicos, podem ser destacados os de suporte:

- (i) a identificação e aplicação das tecnologias disponíveis para o PLN, com enfoque nos pacotes de funcionalidades disponíveis para as linguagens R e Python;
- (ii) a estruturação de base textual (*corpora*)² dos discursos parlamentares compreendendo as legislaturas de número 51, 52, 53, 54 e 55;
- (iii) a disponibilização dos dados, scripts de programação e resultados em repositório público com a finalidade de incentivar novos estudos sobre o tema e de prover meios para a reprodutibilidade da pesquisa;

² *Corpus* é uma população de textos a ser analisado extraído do *corpora* (forma plural de *corpus*), que é uma grande coleção de textos, um corpo de material escrito ou falado sobre a qual uma análise linguística é baseada.

e os de caráter analítico:

- (iv) a construção dos sintagmas³, ou n-gramas, com grupos de duas palavras e validação de *collocations*⁴;
- (v) a identificação de padrões do discurso, análise de convergência ideológica e posicionamento político-partidário na linha do tempo;
- (vi) a identificação de grupos por meio da aplicação de classificadores e técnicas de aprendizagem de máquina.

Este relatório está estruturado em 7 capítulos, iniciando por esta introdução. O Capítulo 2 aborda o discurso parlamentar e as bases da PLN. O Capítulo 3 apresenta os mecanismos de leitura dos dados do discurso e de preparação inicial do universo de textos que constituem o *corpora*. No Capítulo 4, técnicas do PLN são aplicadas a subconjuntos do universo de textos, os *corpus*, sobre os quais são efetuadas as primeiras análises exploratórias. O Capítulo 5 traz uma abordagem estatística para a análise do discurso e propõe um indicador para a aferição da identidade ideológica entre partidos. O Capítulo 6 introduz os conceitos iniciais do campo da aprendizagem de máquina e descreve ensaios de aplicação das técnicas de aprendizagem supervisionada sobre o discurso parlamentar. Por fim, são apresentadas as conclusões finais e recomendações para trabalhos futuros.

Os scripts de programação mencionados nos capítulos que seguem são referenciados pelos nomes dos respectivos arquivos e estão disponíveis no repositório <https://github.com/Cefor/DiscursoDeputados>.

³ Lista de ocorrência de grupos de palavras, com tamanhos variados, repetidos ao longo de um texto/*corpus* com indicação da quantidade de repetições.

⁴ *Collocations* (ou colocações) são expressões consistindo de duas ou mais palavras que correspondem a uma forma convencional de dizer coisas num idioma.

2 DISCURSO PARLAMENTAR E O PROCESSAMENTO DE LINGUAGEM NATURAL

Segundo o Ferreira (2001), discurso é

“Peça oratória proferida em público ou escrita como se tivesse de o ser. Exposição metódica sobre certo assunto; arrazoado.”

Gnerre (1991, p. 5), lembrando Pierre Bourdieu, afirma que "o poder da palavra é o poder de mobilizar a autoridade acumulada pelo falante e concentrá-la num ato linguístico", do qual um dos mais eloquentes exemplos é o discurso político. Para se compreender a política, faz-se necessário conhecer sobre o que os atores políticos estão dizendo e escrevendo. Assim, o discurso político é o hiperônimo⁵ do sintagma discurso parlamentar.

Discurso parlamentar pode ser conceituado como aquele que é pronunciado pelos membros do parlamento. No caso da Câmara dos Deputados, refere-se ao uso da palavra por um deputado federal nas sessões realizadas no Plenário, que reúne a totalidade de seus membros (PAIVA, 2007). Trata-se, de fato, de uma das práticas sociais estruturadas, na Câmara dos Deputados, que mais visibilidade oferece ao parlamentar, uma vez que, mediante a expressão de opiniões e do posicionamento político, ainda que afeta a um gênero integrante da ordem discursiva da Casa, desfruta de reconhecimento não apenas internamente, mas repercute para além das fronteiras institucionais, especialmente nos meios de comunicação de massa (PAIVA, 2007).

Por ser o principal meio de atuação do deputado, o discurso parlamentar é cercado de cuidados regimentais que estabelecem condições e circunstâncias para o uso da palavra no Plenário. Contudo, o regramento não cerceia a fonte do discurso, que pode ser da lavra do próprio parlamentar, que o prepara com antecedência ou o profere de improviso.

Portanto, todos os pronunciamentos de deputados passam pela revisão de profissionais de taquigrafia e linguística que realizam exame minucioso dos discursos, a fim de livrá-los de inconsistências, erros, ambiguidades, referências equivocadas, incongruências, procurando sempre manter o estilo do orador, a fidelidade às suas ideias e o devido cuidado para não

⁵ 3 Hiperônimo: elemento superordenador, em oposição a hipônimo, que é elemento ordenado.

interferir negativamente na mensagem política que pretende o deputado passar por meio de sua manifestação da tribuna (SOUZA, 2009).

Neto (2008, p. 61) declara o seguinte a respeito desse tipo de trabalho:

É na revisão textual consciente, detalhista, competente, que o conteúdo vai ser aprimorado, no que diz respeito à coesão e à coerência, aos erros ortográficos, aos erros conceituais, enfim, aos deslizes praticados pelo autor.

Logo, o discurso parlamentar passa por um filtro antes de ser publicado, conhecido por retextualização, que lhe confere gênero próprio e objetiva melhor comunicar a mensagem do autor que, por princípio, representa a vontade dos seus eleitores.

Uma vez que o discurso é um modo de representar aspectos do mundo, a articulação de mais de um deles reúne diferentes perspectivas de compreensão da realidade social. Essa relação dialógica incrementa a força argumentativa presente no processo de legitimação da principal voz representada. Nesse sentido, compreender a necessidade do discurso parlamentar e a respectiva influência no Processo Legislativo, do qual resultarão as leis que vão atingir direta ou indiretamente a vida de todos os cidadãos brasileiros, é de vital importância.

Em outras palavras, quer dizer que a atuação de um parlamentar deve ser avaliada pelo conjunto da obra, não apenas por pronunciamentos isolados, pois esses carregam o peso do momento e do ambiente em que foram proferidos. Há que se considerar a sequência de eventos para se compreender a evolução do discurso e desta extrair o conhecimento sobre o processo político. Portanto, mecanismos apropriados são necessários para dar conta dessa abordagem.

Em seu artigo *Data Mining and Knowledge Discovery*, publicado em 1996, Fayyad cunhou a expressão Descoberta de Conhecimentos em Bases de Dados, ou *Knowledge Discovery in Databases*, definido por ele como o “processo não trivial de identificação de padrões nos dados que sejam válidos, novos, potencialmente úteis e inteligíveis” (FAYYAD, 1996). Na ótica de Fayyad (1996), a busca de novos conhecimentos em coleções de dados envolve

aspectos intelectuais e tecnológicos projetados para procurar conhecimentos e não para simplesmente manipular dados.

Falcão (2003) utilizou base de discursos parlamentares para propor método de classificação temática em bases de dados textuais indexadas com auxílio de vocabulários controlados⁶. Segundo o autor, “a classificação temática de bases de dados textuais através da atribuição de temas é uma forma de contextualização das informações armazenadas e agrega significado e propósito a elas, possibilitando assim a geração de novos conhecimentos”.

Zhang et al. (2009) afirmam que a capacidade de expressar sentido de uma palavra depende das demais palavras que a acompanham. Quando uma palavra aparece acompanhada por um conjunto de termos, maiores são as chances desse conjunto possuir um significado relevante. Isso significa que não apenas a palavra, mas também a informação contextual é útil para o processamento de informações.

Silva e Souza (2014) destacam que o texto não é um simples amontoado aleatório de palavras, mas que a ordem da colocação das palavras é que produz o significado. O estudo da co-ocorrência das palavras pode indicar que as palavras estão relacionadas diretamente, por composicionalidade ou afinidade, ou indiretamente, por semelhança. Portanto, a base da linguística empírica consiste em encontrar, a partir da frequência de co-ocorrências observadas, as dependências significativas entre os termos. Esses termos adjacentes são denominados n-gramas.

Os modelos de linguagem n-gramas foram desenvolvidos no âmbito da Estatística pelo matemático russo Andrey Markov (1856-1922) com a finalidade de reconhecer padrões estatísticos do uso da língua baseados em cadeias, conhecidas como cadeias de Markov.

Villavicencio et al. (2010) destacam que muitas pesquisas têm buscado automatizar a aquisição lexical e compreender a formação dos recursos lexicais. Os n-gramas são relevantes ao tratamento dos recursos lexicais e importantes insumos informacionais para diversas aplicações relacionadas ao Processamento de Linguagem Natural. O PLN é uma

⁶ Vocabulários controlados são listas de vocábulos utilizados em linguagens de indexação para exprimir o conteúdo semântico de documentos.

subárea da Inteligência Artificial e da Linguística que estuda os problemas da geração e compreensão automática de línguas humanas naturais.

Wang e Liu (2011) apontam que muitos trabalhos têm como foco dominante a identificação e extração n-gramas. Devido à complexidade desses processos, diferentes abordagens têm sido empregadas: (1) métodos estatísticos; (2) informações linguísticas; (3) métodos híbridos, que combinam os dois primeiros.

Evert e Krenn (2005) efetuaram cálculo estatístico das medidas de associação das palavras contidas no texto. Nos testes empíricos esses autores utilizaram um subconjunto de oito milhões de palavras extraídas de um corpus constituído de um jornal escrito no idioma alemão. Pedersen et al. (2015) trabalharam num contexto independente de linguagem baseados em métodos estatísticos.

Machado et al. (2010) afirmam que o PLN visa promover um nível mais alto de compreensão da linguagem natural através do uso de recursos computacionais, com o emprego de técnicas para o rápido processamento de texto. Ressaltam que minerar dados do tipo texto (*text mining*) é um método interdisciplinar que envolve as áreas de recuperação de informação, aprendizagem de máquina, estatística, linguística computacional e mineração de dados. Cada uma dessas áreas, ou a intersecção das mesmas, é usada para transformar o texto em um formato que a máquina consiga processá-lo e entendê-lo.

Santos et al. (2014) analisaram 24 estudos aplicando 11 técnicas diferentes de PLN na mineração de textos e concluíram que a ontologia⁷ se mostrou a mais recorrente e eficiente.

Toledo et al. (2014) aplicaram técnicas de PLN e aprendizagem de máquina à análise clínica do discurso, concluindo que os métodos utilizados são fortes candidatos para a substituição de métodos de seleção manual.

⁷ Em Ciência da Computação, Sistemas de Informação e Ciência da Informação, uma ontologia é um modelo de dados que representa um conjunto de conceitos dentro de um domínio e os relacionamentos entre eles. É utilizada como uma forma de representação de conhecimento sobre o mundo ou alguma parte deste e para realizar inferência sobre os objetos do domínio.

Aranha e Passos (2006), considerando em particular o processo de descoberta de conhecimento, afirmam que as práticas de PLN são meios agregadores de valores semânticos ao texto, capazes de gerar benefícios na busca por padrões específicos.

Hearst (1999) formulou definição mais sofisticada defendendo “o uso de grandes coleções de texto on-line para descobrir novos fatos e tendências sobre o próprio mundo”.

Feinerer, Hornik e Meyer (2008) apontam que o benefício da mineração de texto vem com a grande quantidade de informações valiosas latentes em textos que não estão disponíveis em formatos de dados estruturados clássicos por várias razões: o texto sempre foi a maneira padrão de armazenar informações por centenas de anos e, principalmente, tempo, pessoal e restrições de orçamento nos proíbem de trazer textos para formatos bem estruturados.

Markham, Kowolenko e Michaelis (2015) descreveram como a análise de textos não estruturados, utilizando big data e PLN, podem dar suporte à tomada de decisão crítica sobre o desenvolvimento de novos produtos. Com respeito ao suporte à tomada de decisão, os mesmos autores destacam que o PLN é poderosa ferramenta, visto que se presta à execução de tarefas como:

- Segmentação morfológica: identifica e relaciona morfemas como “competidor”, “competidores” e “competição”.
- Análise: compreende e analisa a estrutura de uma sentença.
- Identificação de ambiguidades: diferencia termos similares e frases e analisa usos irregulares como gíria, sarcasmo, exagero ou atenuação.
- Análise de sentimento: determina o conteúdo emocional de um texto.
- Análise do discurso: segue a discussão de uma sentença a outra para identificar esclarecimentos, elaborações, e adições na informação.
- Reconhecimento de entidade: encontra nomes próprios e identifica o tipo do nome (pessoa, lugar, coisa, marca, etc).
- Extração de relacionamento: encontra a relação entre as entidades identificadas.
- Extração de informação: identifica informação específica sobre uma entidade.

Grimmer e Stewart (2013) reconhecem os benefícios do PLN e o quanto o processamento automatizado de textos reduz custos e esforços de análise de grandes coleções de texto. Contudo, alertam para as possíveis armadilhas das promessas de modelos prontos para responder a qualquer questão. Ressaltam que métodos automatizados não substituem um pensamento cuidadoso e uma leitura atenta, além de exigirem uma validação extensa e específica do problema. Argumentam, também, que para que o processamento automatizado de texto se torne uma ferramenta padrão para cientistas políticos, os pesquisadores da área devem contribuir com a criação de formas robustas de validação dos métodos.

De forma geral, sistemas de geração de linguagem natural convertem informação de bancos de dados de computadores em linguagem normalmente compreensível ao ser humano, e sistemas de compreensão de linguagem natural convertem ocorrências de linguagem humana em representações mais formais, facilmente manipuláveis por programas de computador. Nesse contexto, o leque de possibilidades é vasto e pode ampliar a compreensão da relação entre as expressões linguísticas e os acontecimentos mundanos.

No presente trabalho, especificamente, a abordagem metodológica se baseia nos passos fundamentais do roteiro clássico da mineração de textos, ilustrado na Figura 2.1. O problema e os objetivos específicos já foram enunciados no Capítulo 1. Os textos coletados provêm dos discursos parlamentares das últimas 5 (cinco) legislaturas. Os capítulos que seguem descrevem como as demais etapas da mineração de textos foram conduzidas nesta pesquisa.




Figura 2.1: Roteiro clássico da mineração de textos (adaptado de Kwartler (2018)).

3 ESTRUTURAÇÃO DE CORPORA

Cientistas políticos têm usado a análise automática de conteúdo em um conjunto diversificado de textos. Isso inclui arquivos de dados de mídia (YOUNG e SOROKA, 2012); discursos parlamentares em legislaturas de todo o mundo (QUINN et al., 2010); declarações do presidente, do legislador e do partido (GRIMMER, 2010); proposta de legislação e contas públicas (CONGRESSIONAL BILLS PROJECT, 2018); audiências de comitês (COMPARATIVE AGENDAS PROJECT, 2018); tratados (SPIRLING, 2012); artigos de ciência política e muitos outros textos políticos.

Neste trabalho de pesquisa, a matéria prima utilizada para a estruturação de base textual (*corpora*) proveio da coleção de textos dos discursos parlamentares proferidos no Plenário da Câmara dos Deputados ao longo das legislaturas de número 51, 52, 53, 54 e 55, incluindo os anos de 2000 a 2017.

3.1 LEITURA DOS DADOS

A Câmara dos Deputados provê o serviço de Dados Abertos – Legislativo⁸, que oferece uma coleção de recursos para acesso direto aos dados legislativos produzidos no exercício da atividade parlamentar. Estão disponíveis dados sobre deputados, órgãos legislativos, proposições, sessões plenárias e reuniões de comissões. Nesta fase, foram lidos e processados 345.217 discursos de deputados em inteiro teor.

A tarefa consistiu nos seguintes passos: recuperar a lista de sessões plenárias no período; para cada sessão, obter as fases; para cada fase, obter os dados básicos dos discursos proferidos; para cada discurso, recuperar e decodificar o inteiro teor. Para tanto, foram criados scripts – na linguagem R (versão 64 3.4.3) e no ambiente integrado de desenvolvimento RStudio (versão 1.1.383) –, que fazem requisições ao portal da Câmara por meio do protocolo HTTP (Hypertext Transfer Protocol)⁹ e do método GET¹⁰, e

⁸ <http://www2.camara.leg.br/transparencia/dados-abertos/dados-abertos-legislativo/dados-abertos-legislativo>

⁹ Hypertext Transfer Protocol (HTTP) é o método utilizado para enviar e receber informações na web. É baseado em requisições e respostas entre cliente (navegador ou dispositivo que fará a requisição) e servidor (computador que hospeda a aplicação requisitada).

¹⁰ Os métodos HTTP, também conhecidos como verbos, identificam qual ação deve ser executada em um determinado recurso. O método GET é utilizado quando se deseja realizar uma pesquisa por meio de alguns

SessoesReunioes	
Disponibiliza serviços de acesso aos dados das sessões plenárias e das reuniões de comissões realizadas na Câmara dos Deputados	
Métodos	
Nome	Descrição
ListarDiscursosPlenario	Retorna a lista dos deputados que proferiam discurso no Plenário da Câmara dos Deputados em um determinado período.
ListarPresencasDia	Retorna a lista de presença de deputados em um determinado dia.
ListarPresencasParlamentar	Retorna as presenças de um deputado em um determinado período.
ListarSituacoesReuniaoSessao	Retorna a lista de situações para as reuniões de comissão e sessões plenárias da Câmara dos Deputados
ObterInteiroTeorDiscursosPlenario	Retorna o inteiro teor do discurso proferido no Plenário.

Figura 3.1: Página do serviço de acesso a dados das sessões plenárias¹¹.

recebem os dados resultantes no formato XML (eXtensible Markup Language)¹². A Figura 3.1 ilustra a página do serviço de acesso a dados das sessões plenárias, com destaque aos métodos utilizados: ListarDiscursoPlenario e ObterInteiroTeorDiscursoPlenario.

O método ListarDiscursoPlenario (Figura 3.2) retorna a relação das sessões plenárias em dado período, a qual contém uma lista com as fases da sessão, que contém outra lista com os dados dos discursos.

O script “01_LeituraXMLSessaoDiscurso.R” foi desenvolvido para efetuar as chamadas ao método ListarDiscursoPlenario. Para cada ano, compreendido entre 2000 e 2017, os dados foram consolidados em um arquivo denominado "discurso_AAAA.csv", com os seguintes campos: codigoSessao, dataSessao, numeroSessao, tipoSessao, codigoFase, descricaoFase, numeroQuarto, numeroInsercao, numeroOrador, nomeOrador, partidoOrador, ufOrador, txtIndexacao, sumario.

poucos parâmetros inseridos na URL (Uniform Resource Locator), ou, popularmente, no endereço de rede no qual se encontra o recurso.

¹¹<http://www2.camara.leg.br/transparencia/dados-abertos/dados-abertos-legislativo/webservices/sessoesreunioes-2>

¹² XML (eXtensible Markup Language) é um formato para a criação de documentos com dados organizados de forma hierárquica, por meio de marcações específicas.

ListarDiscursosPlenario

Parâmetros

Nome	Valor	Descrição
DataIni	<i>Date (Obrigatorio)</i>	Data início do período desejado (formato: DD/MM/AAAA)
DataFim	<i>Date (Obrigatorio)</i>	Data de fim do período desejado (formato (DD/MM/AAAA)
CodigoSessao	<i>String (Opcional)</i>	Código da sessão a ser pesquisada
ParteNomeParlamentar	<i>String (Opcional)</i>	Parte do nome do Deputado a ser pesquisada
SiglaPartido	<i>String (Opcional)</i>	Sigla do Partido do Deputado
SiglaUF	<i>String (Opcional)</i>	Sigla da UF do Deputado

Retorno

SessoesDiscurso (LIST<Sessao>): Lista das sessões plenárias contendo os discursos proferidos.

Nome	Valor	Descrição
Codigo	string	Código da sessão plenária
Data	Date	Data em que ocorreu a sessão
Numero	Int	Número da sessão
Tipo	String	Tipo da sessão
FasesSessao	LIST <faseSessao>	Lista contendo as fases da sessão com os discursos proferidos

FaseSessao

Atributos

Nome	Valor	Descrição
Codigo	String	Código da fase da sessão plenária
Descricao	String	Descrição da fase da sessão plenária
Discursos	LIST<Discurso>	Lista dos discursos proferidos durante a fase da sessão

Discurso

Retorno

Discurso: dados do discurso proferido no Plenário

Nome	Valor	Descrição
Orador	Orador	Dados do parlamentar que proferiu o discurso
HorainicioDiscurso	DateTime	Hora que parlamentar iniciou o discurso
NumeroQuarto	int	Número da fração taquigráfica que identifica o início do discurso
NumeroInsercao	String	Número da inserção taquigráfica que identifica o início do discurso
Sumario	Strin	Sumário do discurso

Figura 3.2: Método ListarDiscursoPlenario: parâmetros de consulta e hierarquia dos dados retornados.

Uma vez recuperados os dados básicos do discurso, o método `ObterInteiroTeorDiscursosPlenários` entra em ação por meio do script “02_LeituraXMLDiscursoInteiroTeor.R”, que percorre cada registro dos arquivos “discurso_AAAA.csv” e recupera o inteiro teor de cada discurso (informando os parâmetros `codSessao`, `numOrador`, `numQuarto` e `numInsercao`). Ao final, é gerado um arquivo denominado “discurso_AAAA_dit.csv”, com os campos `id`, `horaInicioDiscurso`, `discurso` (posteriormente, por conveniência, a estrutura desses arquivos é alterada para: `AnoSeq`, `DataHora` e `Discurso`). A Figura 3.3 ilustra os parâmetros do método `ObterInteiroTeorDiscursosPlenários` e a estrutura dos dados retornados.

Os discursos em inteiro teor estão codificados no sistema Base64, que é um método para codificação de dados para transferência pela Internet fundado no protocolo MIME (Multipurpose Internet Mail Extensions). O MIME provê mecanismos para o envio de informações por correio eletrônico, incluindo caracteres não utilizados no idioma inglês, usando codificações diferentes do ASCII, assim como formatos binários contendo imagens, sons, filmes, e programas de computador.

ObterInteiroTeorDiscursosPlenario		
Parâmetros		
Nome	Tipo	Descrição
<code>codSessao</code>	<i>String (Obrigatorio)</i>	Código que identifica uma sessão do Plenário
<code>numOrador</code>	<i>Inteiro (Obrigatorio)</i>	Identificador do orador na sessão
<code>numQuarto</code>	<i>Inteiro (Obrigatorio)</i>	Número da fração taquigráfica que identifica o início do discurso
<code>numInsercao</code>	<i>Inteiro (Obrigatorio)</i>	Número da inserção taquigráfica que identifica o início do discurso
Retorno		
Nome	Tipo	Descrição
<code>Nome</code>	String	Nome do parlamentar
<code>Partido</code>	String	Partido do parlamentar
<code>UF</code>	String	UF do parlamentar
<code>horaInicioDiscurso</code>	String	Hora de início do discurso
<code>discursoRTFBase64</code>	String	Íntegra do discurso em formato RTF codificado em Base64

Figura 3.3: Método `ObterInteiroTeorDiscursosPlenários`: parâmetros de consulta e estrutura dos dados retornados.

Nesse sentido, foram desenvolvidas duas funções, `decode_rtf` e `encode_rtf`, que fazem, respectivamente, a conversão de textos do formato Base64 para RTF¹³, e de RTF para Base64. Essas funções, em sua última versão, estão disponíveis no script “05_EncodeDecode.R”. Originalmente, foram programadas no script “04_AjustaDiscursosComTextoLongo.R”, que ajusta o tamanho de dois discursos proferidos em 2011 para o limite suportado pelo tipo de “character” da linguagem R. As referências a esses discursos estão registradas no arquivo “TextoLongo.csv”.

Nesta etapa foi criado o repositório público para registro dos passos caminhados e para a disponibilização dos scripts de programação e dos dados/informações resultantes¹⁴. A execução em sequência dos scripts deve produzir os mesmos resultados, atendendo aos critérios de reprodutibilidade. Foi escolhida a plataforma GitHub, na qual é possível hospedar e rever código, gerenciar projetos e criar software de forma colaborativa.

3.2 LIMPEZA PRELIMINAR DOS DADOS DE DISCURSO

Wickham (2014) alertou para o fato de que grande quantidade de esforço é gasto com a limpeza dos dados de forma que estejam preparados para análise, mas que há poucas pesquisas sobre como tornar a limpeza de dados tão fácil e eficaz quanto possível. Muito embora o estudo de Wickham se refira a dados estruturados, organizados em linhas (observações) e colunas (variáveis), o mesmo pode ser observado para dados não estruturados como coleções de texto.

Nesse sentido, as atividades de limpeza preliminar do *corpus* de textos consistiram na remoção dos caracteres de formatação, figuras, tabelas e quadros componentes dos discursos. Esse tipo de informação é considerado lixo quando se trata de PLN, visto que não contribui para a análise dos aspectos da linguagem. Aqui a denominação “limpeza preliminar” deixa subentendida a necessidade de aplicação de outras técnicas de limpeza que são próprias do PLN e que serão discutidas adiante.

¹³ RTF é o acrônimo de Rich Text Format (formato de texto enriquecido), que é um formato de arquivo proprietário de documento desenvolvido pela Microsoft em 1987 e mantido até 2008, com o intuito de facilitar o intercâmbio de documentos entre diversas plataformas. Devido à sua simplicidade e documentação disponível, a maioria dos processadores de texto é capaz de ler e escrever documentos guardados em ficheiros RTF.

¹⁴ <https://github.com/Cefor/DiscursoDeputados>

O script “06_AjustaDiscursoInteiroTeor.R” remove os caracteres de formatação de texto como, por exemplo, os da sequência “\\{ MS Sans Serif;\\{ Symbol;\\{ MS Sans Serif;\\{ Arial;\\}\\{;\\}”. Esse tipo de sequência é oriunda da conversão de arquivos RTF, formato em que os discursos são originalmente transcritos, para a Base64. Como existe uma infinidade de possíveis sequências de formatação, a função `str_retirar` foi escrita para a identificação automática dessas sequências no início de cada discurso, com base em delimitadores de barra invertida (“\”), de forma que a remoção independe da intervenção humana.

Outro ponto tratado foi a presença de quadros, tabelas e figuras que, quando da conversão RTF/Base64, deixam o texto poluído com inúmeros caracteres especiais. Foram identificados marcadores de início e fim dessas estruturas (os mais comuns, respectivamente, “010009000003” e “ffff030000000000”) e a função `retira_fig`, constante do script “07_CorporaRetiraQuadrosFiguras.R”, foi escrita para efetuar a remoção. Então, o script “08_CriaCorporaDiscursoInteiroTeor.R” faz a leitura dos arquivos “discurso_AAAA_dit.csv”, decodifica Base64 para RTF, utiliza a função `retira_fig` e cria os arquivos “Discursos_AAAA.txt” que consistem de um texto único com todos os discursos do respectivo ano. Esses arquivos “txt” foram utilizados para inspeções visuais (com vistas à validação dos algoritmos) e para testes dos pacotes Python.

Após as inspeções visuais, os arquivos “discurso_AAAA.csv” (consolidados em um único arquivo) e “discurso_AAAA_dit.csv” foram convertidos para o formato RDS¹⁵ (script “08_CriaCorporaArquivosDiscursos.R”), constituindo o *corpora* de discursos parlamentares, em Plenário, no período de 2000 a 2017.

¹⁵ O formato de arquivo RDS é nativo da linguagem R e permite a armazenagem de objetos R diretamente. Por ser nativo, é mais eficiente.

4 EXTRAÇÃO DE INFORMAÇÕES DO TEXTO

Uma vertente do campo de recuperação de informações do texto baseia-se na interpretação extrema do princípio da semântica composicional. Nesses sistemas, o significado de um documento reside unicamente nas palavras nele contidas, isto é, sentenças como “eu vejo o que como” e “eu como o que vejo” significam exatamente a mesma coisa. A ordem e a classe das palavras que formam as sentenças, que por sua vez que formam o documento, não desempenham papel algum na determinação do seu significado. Por que ignora a informação sintática, o modelo que adota essa abordagem é denominado saco-de-palavras (*bag-of-words*) (JURAFSKY e MARTIN, 2008). A presente pesquisa está fundamentada nesse modelo.

4.1 DEFINIÇÃO DE CORPUS POR CRITÉRIOS DE ANÁLISE

Quando se deseja investigar determinado fenômeno por meio da análise do conteúdo dos textos de uma coleção (*corpora*), é preciso definir o subconjunto de elementos com as características a serem estudadas (*corpus*).

Com essa finalidade foi escrita a função `corpus_por_criterio` (script “10_CorpusPorCriterios.R”), que produz o *corpus* com as características do estudo pretendido, com base em conjunto predefinido de tipos de sessões plenárias e nos seguintes parâmetros:

- `discurso`: é um *data frame* (conjunto de dados) contendo a coleção de discursos que compõe o *corpora*;
- `ini` e `fim`: anos inicial e final do período a ser analisado;
- `partido`: sigla do partido cujos discursos serão extraídos;
- `codigoFase`: vetor com os códigos das fases das sessões em que os discursos foram proferidos; os códigos possíveis são **AB** (Abertura), **BC** (Breves Comunicações), **CG** (Comissão Geral), **EN** (Encerramento), **GE** (Grande Expediente), **OD** (Ordem do Dia) e **PE** (Pequeno Expediente).

O conjunto de sessões plenárias definido exclui os tipos honoríficos e solenes, visto que se destinam a comemorações ou homenagens especiais, ou, ainda, à recepção de altas personalidades, distanciando-se, portanto, da pauta política central. As sessões remanescentes são: Comissão Geral, Comissão Representativa, Deliberativa Extraordinária, Deliberativa Ordinária, Extraordinária da Câmara dos Deputados, Extraordinária do Congresso Nacional, Não Deliberativa de Debates, Ordinária da Câmara dos Deputados, Ordinária do Congresso Nacional, Preparatória e Reforma Previdenciária.

A função `corpus_por_criterio` faz uso da função `retira_fig`, comentada na seção 3.2, para a remoção de figuras, tabelas e quadros constantes dos discursos. Por fim, grava arquivo no formato "corpus_partido_ini_fim.rds" com os dados filtrados.

Antes de se iniciar a busca por informações no texto, dois passos fundamentais são necessários para a análise do *corpus*: pré-processamento e tokenização. O script "11_LimpaCorpusParaAnalise.R" contém a implementação dessas funcionalidades.

4.2 PRÉ-PROCESSAMENTO DO CORPUS

Com vistas a alcançar os objetivos específicos definidos no Capítulo 1, toda construção de saco-de-palavras efetuada foi precedida das seguintes etapas de pré-processamento:

- conversão dos caracteres do texto para minúsculo;
- remoção de números;
- remoção da pontuação;
- remoção dos plurais;
- remoção dos sinais de acentuação;
- remoção das *stopwords*;
- remoção de espaços em branco;
- remoção dos *tokens* com comprimento igual a 1 (um).

Tais etapas foram contempladas na função `tm_clean` (script "11_LimpaCorpusParaAnalise.R"), que faz uso do pacote **tm** (*text mining*) escrito para a linguagem R.

Converter ou não caracteres do texto para minúsculo é uma questão da opção pela diferenciação ou não entre maiúsculas e minúsculas. Pode-se optar por não diferenciar “REFORMA” de “reforma”; porém, pode ser útil diferenciar Oliveira (nome próprio) de oliveira (árvore). Uma vez que as sessões plenárias são conduzidas à luz de regimento próprio, protocolar, e que a transcrição dos discursos passa pelo processo de retextualização, considera-se que o vocabulário utilizado é, em boa parte, homogêneo. Nesses casos, abrir mão da diferenciação entre maiúsculas e minúsculas traz benefícios operacionais, à custa de prejuízo semântico menor.

Os números podem ou não ser relevantes para uma análise. Normalmente, têm importância no estudo de temáticas específicas, nas quais se espera obter informações expressas numericamente. Neste trabalho, optou-se pela remoção.

A pontuação fornece contexto gramatical que suporta a compreensão. Entretanto, para sacos-de-palavras, que ignoram a informação sintática, os sinais de pontuação são, geralmente, removidos.

Outra opção deste estudo foi a remoção de plurais, no sentido de agrupar palavras morfológicamente relacionadas. A morfologia é importante na PLN porque a linguagem é produtiva, isto é, em qualquer texto, encontraremos palavras que não vimos antes e que não estão em um dicionário pré-compilado. O plural é um desses casos, especialmente na língua portuguesa cujas regras de formação são complexas. Com esse propósito, foi desenvolvida a função `remove_plural`, constante do script “05_EncodeDecode.R”, que implementa as seguintes regras de formação, nessa ordem:

- conversão dos sufixos “ões”, “ãos” e “ães”, no plural, para o sufixo “ão”, no singular;
- conversão dos sufixos “ais”, “éis”, “óis”, “uis”, no plural, para os sufixos “al”, “el”, “ol”, “ul”, no singular;
- supressão do sufixo “es” para substantivos terminados em “r”, “z” e “s”;
- conversão dos sufixos “ens”, “ins”, “ons”, “uns”, no plural, para o sufixo “m”, no singular;
- supressão do “s” ao final das palavras.

A remoção dos sinais de acentuação foi efetuada para dar suporte a outro processo morfológico, denominado *stemming*. Trata-se do processo de ignorar os afixos e manter apenas o radical. O benefício dessa prática depende dos objetivos da aplicação e, conforme o caso, melhora ou prejudica o desempenho de uma consulta. No presente estudo, o uso de radicais resultou na inflação da frequência dos *tokens*, descaracterizando o saco-de-palavras, sendo, portanto, excluído das etapas de pré-processamento.

Stopwords são palavras com pouco significado em algumas aplicações de PLN, como a recuperação e classificação de informações, o que significa que essas palavras não são muito discriminatórias. Geralmente, artigos e pronomes são classificados como *stopwords*. A ideia é simplesmente remover as palavras que ocorrem com muita frequência em todos os documentos no *corpus*. Contudo, a escolha da lista de *stopwords* deve ser cuidadosa pois é determinante para o alcance dos objetivos. Neste trabalho, a construção do conjunto de *stopwords* teve como principal foco o objetivo específico “identificação de padrões do discurso, análise de convergência ideológica e posicionamento político-partidário na linha do tempo”, passando por diversos filtros e inspeções visuais, auxiliadas por recursos de nuvens de palavras e gráficos de frequência (como veremos adiante). Foram criados sete níveis de listas conforme os arquivos descritos a seguir:

- stopwords_portugues.txt: contém lista padrão de palavras disponível no pacote **tm**, acrescida de novas observações, basicamente, artigos, pronomes e verbos mais comuns como ter, ser, dar e estar;
- stopwords_partidos.txt: contém a relação das siglas dos partidos existentes entre os anos de 2000 e 2017; a menção a partidos no discurso parlamentar é recorrente e protocolar, não agregando valor à análise do objetivo em foco;
- stopwords_membros_mesa.txt: contém a relação de nomes dos membros da Mesa Diretora da Câmara dos Deputados no período de 2000 a 2017; por questões regimentais, os nomes de membros da Mesa aparecem com frequência no discurso, sendo necessária a remoção para garantir a impessoalidade nos dados de análise;
- stopwords_nomes_compostos.txt: contém a relação de outros nomes compostos, em geral de parlamentares, que aparecem com frequência no discurso;

- stopwords_nomes_simples.txt: contém a relação de nomes simples que aparecem com frequência no discurso;
- stopwords_discurso.txt: contém a relação de palavras frequentes do discurso, como ‘artigo’, ‘aprovado’, ‘bancada’, ‘brasil’ e outras que, por estarem estreitamente ligadas à formalidade do Processo Legislativo, são pouco discriminatórias;
- stopwords_bigramas.txt: contém bigramas frequentes do discurso, como “regimento interno”, “constituicao justica”, “departamento revisao” e outros que, também por serem intrínsecos ao Processo Legislativo, são pouco discriminatórios.

A remoção de espaços em branco e das palavras de tamanho igual a 1 (um) utilizam as funções do pacote **tm** e finalizam as etapas de pré-processamento.

4.3 TOKENIZAÇÃO

Tokenização ou segmentação de palavras é a tarefa de dividir um texto em unidades mínimas chamadas *tokens*, onde cada *token* pode ser uma palavra, um número, um sinal de pontuação ou outra estrutura pertencente à linguagem (MANNING e SCHÜTZE, 1999).

Em geral, a divisão de *tokens* é feita a cada ocorrência de espaço em branco no texto. Contudo, a complexidade da tokenização varia de acordo com a complexidade do próprio idioma, com a definição do problema a ser estudado e com o modelo escolhido para aplicação da PLN. Para o presente estudo, a tokenização é sempre precedida das etapas descritas na subseção 4.2.1.

O saco-de-palavras (ou saco-de-*tokens*) com a respectiva contagem de frequência dos termos é o produto final da tokenização. É a partir das frequências estimadas que se inicia a busca por informações no texto.

Uma técnica do PLN para registro e tratamento da frequência dos termos é a Matriz Termo Documento – MTD (ou a transposta, Matriz Documento Termo – MDT), que descreve a frequência dos termos que ocorrem em um conjunto de documentos (ou discursos). Em uma

MTD, as linhas correspondem a termos (*tokens*, palavras, n-gramas ou frases), as colunas correspondem a documentos e as células correspondem ao peso dos termos, que pode ser dado pela frequência absoluta ou por outra estimativa que represente a importância do termo no *corpus*.

4.3.1 Frequência de termos relativa à frequência inversa de documentos (Term Frequency-Inverse Document Frequency)

As informações básicas usadas na ponderação de um termo são a frequência do termo e a frequência do documento.

A informação captada pela frequência do termo é o quão saliente uma palavra se encontra dentro de um documento. Quanto maior a frequência, maior a probabilidade de que a palavra seja uma boa descrição do conteúdo do documento.

A segunda quantidade, a frequência do documento, pode ser interpretada como um indicador do quão informativa a palavra é. Palavras limitadas a alguns poucos documentos são úteis como elementos discriminatórios desses documentos, com forte significado, ao contrário das palavras que ocorrem frequentemente ao longo de todo o *corpus*.

Uma forma de combinar as duas informações é a técnica da frequência dos termos relativa à frequência inversa dos documentos (Term Frequency-Inverse Document Frequency – TFIDF), na qual a frequência dos documentos é escalonada de forma logarítmica (MANNING e SCHÜTZE, 1999), como na Equação 1.

$$w_{i,j} = tf_{i,j} * \log\left(\frac{N}{df_i}\right) \quad (1)$$

onde

$w_{i,j}$ = peso da palavra i no documento j

$tf_{i,j}$ = frequência da palavra i no documento j

$df_{i,j}$ = quantidade de documentos que contêm a palavra i

N = quantidade de documentos

Observa-se, da Equação 1, que na medida em que df_{ij} se aproxima de N , o peso da palavra w_{ij} tende a zero (baixa ou nenhuma importância). Por outro lado, o peso w_{ij} cresce com tf_{ij} .

O script “11_LimpaCorpusParaAnalise.R” cria a MTD utilizando a função `TermDocumentMatrix`, do pacote **tm**, aplicando a técnica de ponderação TFIDF.

4.3.2 Ajuste de esparsidade da Matriz Termo Documento

Matrizes do tipo MTD, quando resultantes do processamento de grandes quantidades de texto, são da ordem de milhões de células. No caso do discurso parlamentar, em média, são registrados por ano 6.000 discursos, num total aproximado de 15.000 termos, o que equivaleria a uma MTD com 90 milhões de células.

Matrizes dessa magnitude são esparsas, isto é, contêm majoritariamente zeros em suas células. Portanto, faz-se necessário reduzir o tamanho de MTDs esparsas, de forma a otimizar o processamento das informações.

Uma técnica de redução da esparsidade consiste em se estipular uma frequência de corte de zeros (fcz) para cada termo na MTD. Em outras palavras, consiste em determinar a porcentagem de zeros admissível para cada termo. Logo, quanto mais próxima de 1 (100%), mais termos serão mantidos na MTD.

O script “11_LimpaCorpusParaAnalise.R” utiliza a função `removeSparseTerms`, do pacote **tm**, para a redução da esparsidade. A frequência de corte é iniciada em 0,9999 e ajustada dinamicamente para o primeiro valor de fcz capaz de reduzir as dimensões da MTD.

4.3.3 Bigramas

O processo de tokenização pode ser ajustado para efetuar a divisão do texto em bigramas, ou seja, *tokens* com duas palavras que ocorrem consecutivamente no texto. Os bigramas são comumente utilizados como base para a análise estatística de textos e ajudam a estimar a probabilidade condicional de uma palavra, dada a palavra precedente (JURAFSKY e MARTIN, 2008).

Bigramas são mais ricos em significado do que a apuração de palavras simples, sendo mais úteis na extração de informações do texto. Alguns exemplos de bigramas extraídos dos discursos são: “reforma previdencia”, “reforma agraria”, “direitos humanos”, “carga tributaria” e outros.

O script “11_LimpaCorpusParaAnalise.R” utiliza a função `unnest_tokens`, do pacote **tidytext**, para a produção dos bigramas.

4.4 PESQUISA EXPLORATÓRIA

Ao final da execução do script “11_LimpaCorpusParaAnalise.R”, arquivo no formato “corpus_partido_ini_fim_limpo.rds” é gravado com os seguintes objetos:

- `docs`: *corpus* contendo os discursos resultantes da aplicação dos filtros descritos na Seção 4.1, cujos conteúdos foram processados pelas etapas da Seção 4.2;
- `tfq`: vetor com a frequência absoluta dos 2.000 (dois mil) termos mais frequentes do *corpus*, extraídos antes da aplicação do algoritmo TFIDF e dos ajustes de esparsidade;
- `ntokens`: quantidade de palavras no *corpus* extraídas antes da aplicação do algoritmo TFIDF e dos ajustes de esparsidade;
- `bigramas`: vetor dos bigramas identificados no *corpus*, com frequência absoluta maior do que 3 (três), extraídos antes da aplicação do algoritmo TFIDF e dos ajustes de esparsidade;
- `sparse_fcz`: frequência de corte utilizada no ajuste de esparsidade;
- `ntokens_fcz`: quantidade de palavras no *corpus* extraídas depois da aplicação do algoritmo TFIDF e dos ajustes de esparsidade;
- `freq_tdm`: vetor com a frequência absoluta dos 2.000 (dois mil) termos mais frequentes do *corpus*, extraídos depois da aplicação do algoritmo TFIDF e dos ajustes de esparsidade.

Esses objetos constituem a matéria prima para uma pesquisa exploratória, por meio de recursos visuais, que podem revelar pistas ou intuições importantes sobre as informações

contidas no texto. As subseções seguintes ilustram algumas das ferramentas mais comuns utilizadas no PLN.

4.4.1 Nuvens de palavras e gráficos de frequência

Nuvem de palavras é o termo utilizado para um tipo de visualização que amplia a capacidade analítica sobre o conteúdo de textos. Em uma nuvem de palavras, cada palavra tem seu tamanho e intensidade de cor regidos pela relevância em determinado *corpus*. Geralmente, trata-se da contagem simples das ocorrências de determinada palavra no texto: uma palavra citada 200 vezes vai apresentar um tamanho proporcionalmente maior do que uma palavra citada 120 vezes.

Uma palavra repetida várias vezes o é por algum motivo. Nuvens de palavras são, então, um método heurístico de análise. Por si só, não resolvem um problema ou respondem a uma questão de pesquisa, mas apontam caminhos para o que deve ou não receber maior atenção em um texto ou grupo de textos.

No presente estudo, as nuvens de palavras foram amplamente utilizadas para o ajuste fino das etapas de pré-processamento (Seção 4.2), sendo extremamente úteis na determinação das listas de *stopwords*. Isso porque as nuvens reproduzem o óbvio quando os textos estão contaminados com palavras pouco discriminatórias. Por exemplo, é de se esperar que no contexto do discurso parlamentar a palavra “deputado” ocorra com alta frequência, capaz de ofuscar um termo como “educação” que teria maior importância na análise. Essa disparidade é facilmente detectada em uma nuvem de palavras, indicando que o termo “deputado” é forte candidato a *stopword*.

Aliados às nuvens de palavras na análise exploratória de textos são os gráficos de frequência, como histogramas e gráficos de barras, que apresentam os detalhes quantitativos dos termos mais frequentes. Considera-se boa prática de análise o uso combinado dessas ferramentas para se captar as intuições iniciais do processo investigatório.

As figuras 4.1 e 4.2 ilustram a aplicação desses recursos no âmbito dos discursos proferidos pelo PSDB e PT no ano de 2016. A Figura 4.3 ilustra a mesma aplicação para bigramas.




Figura 4.1: Nuvem de palavras e gráfico de barras dos discursos do PSDB em 2016: (a) frequência absoluta; (b) tratamento TFIDF e ajuste de esparsidade.




Figura 4.2: Nuvem de palavras e gráfico de barras dos discursos do PT em 2016: (a) frequência absoluta; (b) tratamento TFIDF e ajuste de esparsidade.




Figura 4.3: Nuvem de palavras e gráfico de barras de frequências absolutas: (a) bigramas dos discursos do PSDB em 2016; (b) bigramas dos discursos do PT em 2016.

As figuras 4.1, 4.2 e 4.3 foram geradas a partir do script “12_NuvemDePalavrasFreq.Rmd”, executado sobre o *corpus* respectivo de cada partido no ano de 2016. Num primeiro olhar sobre essas figuras, tem-se a impressão de que os discursos são semelhantes e abordam as mesmas temáticas, com pequenas variações. Contudo, embora seja importante para o amadurecimento do processo investigatório, a inspeção visual não é suficiente para se avançar em conclusões. Mais adiante, trataremos de testes estatísticos que constituem uma abordagem robusta para a comparação de textos.

4.4.2 Classificadores: clusterização e modelo de tópicos

Uma vertente comum em estatística e ciência da computação defende o uso de métodos de agrupamento (ou clusterização) para classificar documentos de conteúdo semelhante (MURTAGH e LEGENDRE, 2014). Sabe-se que a aplicação ideal de qualquer método de classificação requer sintonia substancial com um problema particular. A necessidade de métodos específicos aos problemas surge porque a classificação só é possível com base em suposições prévias sobre o resultado que se espera encontrar.

A análise de cluster hierárquica clássica usa o conjunto de diferenças para organizar objetos em grupo. Inicialmente, cada objeto é atribuído ao seu próprio cluster e, em seguida, o algoritmo prossegue iterativamente, juntando clusters semelhantes dois a dois, continuando até existir apenas um único cluster. Em cada estágio, as distâncias entre clusters são recalculadas pela fórmula de atualização de dissimilaridade de Lance-Williams (Equação 2), de acordo com o método *complete linkage* que encontra clusters similares (MURTAGH e LEGENDRE, 2014).

$$D(X, Y) = \max_{x \in X, y \in Y} d(x, y) \quad (2)$$

onde

$d(x, y)$ é a distância entre $x \in X$ e $y \in Y$
 X e Y são dois clusters

No R, a função `hclust`, do pacote **stats**, executa, por padrão, o método *complete linkage*. O resultado pode ser apresentado na forma de um dendrograma¹⁶. A Figura 4.4, gerada a partir do script “12_NuvemDePalavrasFreq.Rmd”, ilustra dendogramas referentes à clusterização dos bigramas identificados nos discursos do PSDB e do PT no ano de 2016.

¹⁶ Dendrograma (dendro = árvore) é um tipo específico de diagrama ou representação icônica que organiza determinados fatores e variáveis de acordo com a sua ordenação hierárquica ascendente, assemelhando-se aos ramos de uma árvore que se vão dividindo noutros sucessivamente.




Figura 4.4: Dendogramas referentes à clusterização dos bigramas identificados nos discursos do ano de 2016: (a) PSDB; (b) PT.

Uma rápida interpretação da Figura 4.4 sugere que os discursos dedicaram maior atenção à temática do ensino médio, com ênfase absoluta no caso do PT, ao passo que o PSDB dividiu importância com a temática da reforma da previdência.

Outra técnica bastante utilizada na classificação de textos é o modelo de tópicos, um tipo de modelo estatístico para a descoberta de tópicos abstratos que ocorrem em uma coleção de documentos. O modelo de tópicos é frequentemente usado na mineração de textos para encontrar estruturas semânticas escondidas no corpo do texto.

Uma implementação do modelo de tópicos bastante utilizada é a Alocação Latente de Dirichlet, do inglês, Latent Dirichlet Allocation – LDA (BLEI e JORDAN, 2003). A LDA é um modelo probabilístico generativo de um *corpus*, isto é, parte do princípio de que a geração de um documento segue uma lógica predefinida, na qual a inserção de palavras no texto se baseia em tópicos escolhidos pelo autor, e que cada tópico ocupa um percentual conhecido do texto. Em tese, ao escrever um documento (ou proferir um discurso parlamentar), os seguintes passos seriam efetuados pelo autor:

1. estipular a quantidade N de palavras que o documento terá e a distribuição sob a qual as palavras serão inseridas, por exemplo, a distribuição de Poisson¹⁷ ($N \sim \text{Poisson}(\xi)$);
2. estipular a quantidade k de tópicos e a proporção θ ocupada por tópico no texto; essa proporção é função de um parâmetro α que define a prioridade do tópico no documento, denominado prioridade de Dirichlet, com distribuição multinomial de Dirichlet ($\theta \sim \text{Dir}(\alpha)$);
3. para cada uma das N palavras w_n :
 - a. escolha um tópico z_n e verifique a respectiva proporção ($z_n \sim \text{Multinomial}(\theta)$);
 - b. escolha uma palavra w_n a partir probabilidade multinomial condicionada no tópico z_n , $p(w_n|z_n, \beta)$, onde β é a prioridade da palavra no tópico.

¹⁷ Distribuição de Poisson é uma distribuição de probabilidade de variável aleatória discreta que expressa a probabilidade de uma série de eventos ocorrer num certo período de tempo e se estes eventos ocorrem independentemente uns dos outros.

Assumindo este modelo generativo para uma coleção de documentos, a LDA, então, tenta partir dos documentos para encontrar um conjunto de tópicos que provavelmente geraram a coleção.

Na prática, o algoritmo LDA ajusta os parâmetros k , α e β (AGRAWAL, FU e MENZIES, 2018). Para isso, existem dois tipos diferentes de implementações: (1) o método VEM (Variational Expectation Maximization), que calcula α e β por meio da maximização do valor esperado, e (2) a amostragem de Gibbs, que é um algoritmo de Monte Carlo via Cadeia de Markov, um processo estocástico aproximado para computação e atualização de α e β . Layman et. al. (2016) argumentaram que Gibbs leva a modelos mais estáveis.

Quadro 4.1: Resultado da aplicação dos métodos VEM e Gibbs para os discursos do PSDB no ano de 2016.

# VEM					
##	Topic 1	Topic 2	Topic 3	Topic 4	Topic 5
## [1,]	"previdencia"	"direito"	"militar"	"educacao"	"moeda"
## [2,]	"reforma"	"corrupcao"	"policia"	"ensino"	"mulher"
## [3,]	"direito"	"crime"	"policial"	"medio"	"direito"
## [4,]	"aposentadoria"	"juiz"	"direito"	"escola"	"universidade"
## [5,]	"idade"	"supremo"	"seguranca"	"saude"	"ceara"
## [6,]	"golpe"	"judiciario"	"tema"	"jovem"	"membro"
## [7,]	"salario"	"mulher"	"justica"	"reforma"	"associacao"
## [8,]	"crise"	"tribunal"	"amin"	"fiscal"	"maria"
## [9,]	"contribuicao"	"humano"	"defesa"	"investimento"	"central"
## [10,]	"saude"	"aborto"	"crime"	"energia"	"santo"

# Gibbs					
##	Topic 1	Topic 2	Topic 3	Topic 4	Topic 5
## [1,]	<u>"corrupcao"</u>	<u>"educacao"</u>	"luta" ?	<u>"reforma"</u>	<u>"direito"</u>
## [2,]	"policia"	<u>"ensino"</u>	"homem" ?	<u>"previdencia"</u>	<u>"mulher"</u>
## [3,]	"crime"	<u>"medio"</u>	"filho" ?	"moeda"	"defesa"
## [4,]	"militar"	"escola"	"representante"	"crise"	"violencia"
## [5,]	"juiz"	"saude"	"brasilia"	"banco"	"associacao"
## [6,]	"judiciario"	"ceara"	"movimento"	"idade"	"pessoa"
## [7,]	"policial"	"comunicacao"	"campo"	"economica"	"crianca"
## [8,]	"cidadao"	"jovem"	"junto"	"divida"	"tribunal"
## [9,]	"autoridade"	"professor"	"familia"	"fiscal"	"secretaria"
## [10,]	"lavajato"	"profissional"	"amigo"	"seguranca"	"deficiencia"

Quadro 4.2: Resultado da aplicação dos métodos VEM e Gibbs para os discursos do PT no ano de 2016.

# VEM					
##	Topic 1	Topic 2	Topic 3	Topic 4	Topic 5
## [1,]	"banco"	"educacao"	"educacao"	"corrupcao"	"saude"
## [2,]	"direito"	"ensino"	"mulher"	"direito"	"ceara"
## [3,]	"militar"	"medio"	"saude"	"crime"	"moeda"
## [4,]	"luta"	"associacao"	"direito"	"policia"	"crise"
## [5,]	"homem"	"direito"	"reforma"	"seguranca"	"fiscal"
## [6,]	"agencias"	"energia"	"escola"	"juiz"	"banco"
## [7,]	"democracia"	"componente"	"previdencia"	"militar"	"comunicacao"
## [8,]	"golpe"	"membro"	"violencia"	"judiciario"	"emprego"
## [9,]	"filho"	"universidade"	"movimento"	"eleicao"	"divida"
## [10,]	"reforma"	"ambiental"	"ensino"	"caixa"	"economia"

# Gibbs					
##	Topic 1	Topic 2	Topic 3	Topic 4	Topic 5
## [1,]	" <u>reforma</u> "	"educacao"	" <u>corrupcao</u> "	" <u>direito</u> "	"associacao"
## [2,]	" <u>previdencia</u> "	" <u>ensino</u> "	"crime"	" <u>mulher</u> "	"componente"
## [3,]	"crise"	" <u>medio</u> "	"policia"	"violencia"	"brasilvia"
## [4,]	"banco"	"comunicacao"	"militar"	"homem"	"representante"
## [5,]	"economica"	"ceara"	"seguranca"	"luta"	"anterior" ?
## [6,]	"saude"	"escola"	"policial"	"defesa"	"filho"
## [7,]	"economia"	"estadual"	"constituicao"	"acao"	"maria"
## [8,]	"emprego"	"professor"	"juiz"	"democracia"	"institucional"
## [9,]	"fiscal"	"saude"	"cidadao"	"crianca"	"santo"
## [10,]	"investimento"	"universidade"	"caixa"	"movimento"	"silva"

Os quadros 4.1 e 4.2, gerados a partir dos scripts “15_Topicos.R” e “15_Topicos.Rmd”, apresentam os resultados dos métodos VEM e Gibbs para os discursos do PSDB e PT no ano de 2016. A observação simples dos quadros não é suficiente para indicar a superioridade de um ou de outro método. Importante lembrar que o método requer sintonia substancial com o objetivo em estudo. Por exemplo, ao investigar o objetivo específico convergência ideológica, poderíamos concluir que PT e PSDB adotam o mesmo discurso. É razoável considerar que os tópicos 1, 2, 4 e 5 do método de Gibbs no Quadro 4.1 (destaques em verde) poderiam se traduzir nos temas “corrupção”, “educação/ensino médio”, “reforma da previdência” e “direito da mulher”. O mesmo pode ser dito para o Quadro 4.2, onde os tópicos 1, 2, 3 e 4 de Gibbs são coerentes com os mesmos temas. Contudo, o senso comum e os fatos históricos apontam que PT e PSDB exercem discursos diametralmente opostos.

4.5 ANÁLISE

A lógica da Figura 2.1, apresentada no Capítulo 2, remete ao ponto em que, uma vez executadas as etapas anteriores (definição de *corpus* por critérios de análise, pré-processamento do *corpus*, tokenização e pesquisa exploratória), é chegada a hora de se analisar as informações extraídas na busca por novas intuições, descobertas, resultados ou recomendações.

Na premissa de que o método deve se moldar aos propósitos do estudo, as etapas preparatórias se desenvolveram com o foco no objetivo de identificação de padrões do discurso, análise de convergência ideológica e posicionamento político-partidário na linha do tempo.

Em primeira abordagem, foram criados *corpus* independentes para cada ano, para os partidos DEM, PCdoB, PMDB, PSDB, PSOL, PT e PTB, contendo discursos em Plenário de todas as fases da sessão. Findo o pré-processamento, cada *corpus* passou pela tokenização para a identificação dos unigramas e bigramas. Os resultados foram registrados em representações visuais como as das figuras 4.1, 4.2, 4.3 e 4.4, e dos quadros 4.1 e 4.2.

A escolha dos partidos se deu na expectativa da confirmação de algumas possibilidades, como a de se encontrar evidências claras de diferenças ideológicas nos discursos do PT e PSDB, ou PT e DEM. Os quadros 4.3 e 4.4 apresentam, respectivamente, os resultados de tópicos encontrados para o PT e PSDB, no período de 2010 a 2017, considerando-se os unigramas e bigramas mais frequentes, bem como o algoritmo LDA. Contudo, a inspeção visual aponta forte similaridade de termos e temáticas nos discursos. Dentre os possíveis motivos, destaca-se o fato de que a maior parte dos discursos ocorre na Ordem do Dia, fase da sessão plenária que é regida por pauta comum a todos os partidos.

Conforme comentado nas seções anteriores, a inspeção visual é recurso preliminar e deve ser utilizado para fornecer as impressões iniciais da análise. Ainda que não sirva para inferência, contribui para ilustrar os principais assuntos que ocuparam a agenda da Câmara dos Deputados ao longo dos anos. Porém, a inquietação que motivou a presente pesquisa veio da expectativa de que a análise do discurso por meio do PLN seria capaz de apontar caminhos mais claros, que refletiriam comportamentos específicos ao longo do tempo.

Nesse sentido, técnicas mais robustas de análise, com sustentação em métodos estatísticos e de aprendizagem de máquina, seriam necessárias, assuntos explorados nos próximos capítulos. Também necessária é a definição de mecanismos ou conceitos apropriados para a aferição ideológica. Como a ideologia partidária, num contexto de 35 partidos registrados no Tribunal Superior Eleitoral, beira a utopia, opta-se por buscar a semelhança do discurso em partidos de coalizão.

Quadro 4.3: Tópicos levantados para os discursos do PT, no período de 2010 a 2017, por meio da identificação de unigramas e bigramas e da aplicação da LDA.

ano	unig	bigr	lda
2010	bingo fundo kandir educacao pobreza saude policial seguranca direito eleicao	direito_humano defesa_consumidor salario_minimo codigo_florestal energia_eletrica crime_organizado porto_alegre forca_armada	seguranca policial saude policia reforma droga fundo militar crime direito
2011	saude dru educacao direito mulher orcamento bahia justica royalties musica	direito_humano ciencia_tecnologia royalties_petroleo agricultura_familiar codigo_florestal salario_minimo supremo_tribunal caixa_economica	dru constituicao dinheiro direito corrupcao orcamento justica tribunal uniao interesse
2012	royalties direito educacao veto petroleo vigilante energia saude justica previdenciario	direito_humano royalties_petroleo energia_eletrica supremo_tribunal fator_previdenciario crianca_adolescente anterior_destinouse exercicio_anterior	energia royalties direito consumidor petroleo reducao uniao imposto justica tarifa
2013	saude agente direito codigo civil galerias eleitoral comunitarios campanha educacao	direito_humano agente_comunitarios comunitarios_saude bolsa_familia codigo_civil anterior_destinouse supremo_tribunal piso_salarial	agente saude eleitoral reforma uniao dinheiro gente campanha civil tribunal
2014	galerias policia saude direito justica orcamento reuniao decreto reforma gente	direito_humano meios_comunicacao responsabilidade_fiscal supremo_tribunal campanha_eleitoral agricultura_familiar anterior_destinouse orcamento_impositivo	petrobra policia tribunal justica reuniao orcamento veto anterior corrupcao galerias
2015	mulher saude direito impeachment mina bahia educacao justica seguranca policia	mulher_negra anterior_destinouse direito_humano supremo_tribunal dom_bosco bolsa_familia policia_militar crise_economica	seguranca educacao escola militar policial estadual policia representante bahia porto
2016	educacao moeda ensino corrupcao taxista seguranca policia reforma direito medio	ensino_medio reforma_previdencia combate_corrupcao supremo_tribunal anterior_destinouse direito_humano operacao_lavajato saude_educacao	educacao ensino medio associacao direito energia componente membro universidade ambiental
2017	investigacao reforma estabilidade denuncia corrupcao direito saude crime economia animal	supremo_tribunal reforma_trabalhista viola_caipira eleicao_direta reforma_previdencia anterior_destinou musico_viola policia_rodoviaria	denuncia reforma corrupcao direito eleicao dinheiro economia crise crime supremo

Quadro 4.4: Tópicos levantados para os discursos do PSDB, no período de 2010 a 2017, por meio da identificação de unigramas e bigramas e da aplicação da LDA.

ano	unig	bigr	lda
2010	bingo kandir fundo pobreza combate nominal jogo educacao direito seguranca	codigo_florestal direito_humano energia_eletrica defesa_consumidor fundo_combate combate_pobreza forca_armada santa_maria	bingo jogo fundo pobreza kandir orcamento constituicao dinheiro combate atividade
2011	saude musica mulher executivo justica filipe direito musico orcamento educacao	direito_humano codigo_florestal violencia_mulher bebida_alcoolica produtor_rural ciencia_tecnologia zona_franca salario_minimo	direito mulher violencia seguranca combate luta saude humano familia justica
2012	veto juridicidade energia tecnica adequacao financeira royalties direito petroleo substitutivo	direito_humano energia_eletrica extensao_rural supremo_tribunal oscar_niemeyer royalties_petroleo tarifa_energia assistencia_tecnica	veto constituicao royalties direito petroleo constitucional supremo tribunal distribuicao apreciacao
2013	direito saude codigo orcamento bahia mulher educacao civil transito agente	direito_humano nelson_mandela supremo_tribunal codigo_civil violencia_mulher anterior_destinouse orcamento_impositivo ensino_medio	saude mandela indigena terra direito luta bahia orcamento nelson negro
2014	orcamento saude reuniao justica tribunal direito filho veto defensoria impositivo	direito_humano orcamento_impositivo imposto_renda meios_comunicacao supremo_tribunal tribunal_uniao responsabilidade_fiscal estatuto_desarmamento	orcamento reuniao direito justica tribunal arma estatuto impositivo imposto gente
2015	mulher saude impeachment direito nazare negra justica constituicao mina militar	mulher_negra anterior_destinouse direito_humano dom_bosco supremo_tribunal policia_militar liberdade_religiosa meios_comunicacao	direito seguranca policia violencia militar mulher policial mina crime ambiental
2016	moeda educacao ensino taxista previdencia medio reforma policia seguranca militar	ensino_medio reforma_previdencia supremo_tribunal direito_humano evaristo_arns combate_corrupcao banco_central operacao_lavajato	educacao ensino medio escola saude jovem reforma fiscal investimento energia
2017	animal saude santa mulher arma crime hospital protetora reforma direito	oswaldo_cruz anterior_destinou protetora_animal reforma_previdencia defesa_animal medico_sanitarista sanitarista_oswaldo supremo_tribunal	mulher violencia seguranca crime direito imposto saude policial policia militar

5 ABORDAGEM ESTATÍSTICA

A análise de *corpora* com grande quantidade de texto por meio de métodos estatísticos é um caminho seguro na tentativa de se encontrar o equilíbrio entre intuição e rigor. O Processamento Estatístico de Linguagem Natural é um campo que utiliza métodos quantitativos para o processamento automático da linguagem, incluindo modelos probabilísticos, teoria da informação e álgebra linear (MANNING e SCHÜTZE, 1999).

Neste capítulo são apresentados os métodos utilizados para a comparação dos discursos dos diversos partidos na linha do tempo, bem como os critérios para aferição de similaridade.

5.1 HISTOGRAMA E DENSIDADE DE PROBABILIDADE

Conhecer a distribuição de frequências de um conjunto de dados e saber estimar as probabilidades dos eventos possíveis é o princípio fundamental da análise estatística inferencial. A avaliação de dois conjuntos de dados (amostras) sobre o fato de pertencerem a uma mesma população passa pela capacidade de se mensurar o quanto as suas distribuições de frequências se assemelham.

A similaridade de discursos parlamentares pode ser aferida sob o mesmo princípio, comparando-se a distribuição de frequências (ou histogramas) das palavras contidas no discurso (ou *corpus* de discursos). Nesse sentido, foram desenvolvidas as funções do script “20_Histogramador.R”: `freq_discurso`, que conta as ocorrências de um dado termo em cada discurso proferido no período informado; `histograma`, que consolida essas ocorrências em intervalos de classe que podem corresponder a um dia, semana, mês, bimestre, trimestre, quadrimestre ou ano; e `comparatermo_distfreq`, que faz chamadas às duas anteriores e plota gráficos comparados, entre dois partidos informados, de ocorrências do termo no tempo, de densidade de probabilidade e histogramas.

As figuras 5.1 a 5.5 mostram simulações de cotejamento entre os partidos PT e PSDB no ano de 2016. Para fins ilustrativos, foram consideradas as temáticas identificadas nos quadros 4.1 e 4.2: corrupção, educação, previdência e mulher. Ressalta-se que essa abordagem é ainda exploratória e não tem propósito inferencial.




Figura 5.1: Ocorrências do termo “corrupção” em cada discurso dos partidos PT e PSDB ao longo do ano de 2016.

A Figura 5.1 representa o número de ocorrências do termo “corrupção” em cada discurso dos partidos PT e PSDB, ao longo do ano de 2016, levando em consideração a hora exata em que o discurso foi proferido. A inspeção visual revela relativa discrepância entre as frequências do PT e PSDB nos respectivos instantes do tempo, o que poderia ser um indicador de abordagem e/ou posicionamento diferenciados dos partidos em relação à essa temática.

Observa-se, também, que existe predominância de lacunas em ambos os gráficos, significando que boa parte dos discursos não faz menção ao termo em questão. Essa situação é evidenciada pela Figura 5.2a, na qual o ponto máximo da densidade de probabilidade, para ambos os partidos, ocorre em torno da frequência zero, quando as ocorrências do tema são contadas a cada dia do período. Esse resultado poderia levar à conclusão de que PT e PSDB se posicionam de forma semelhante com relação ao tema “corrupção”. Contudo, uma vez que a comparação se processa em torno de temática definida, é razoável concentrar a análise apenas nos discursos em que o termo estudado tenha frequência maior que zero. A Figura 5.2b ilustra essa condição, situação em que as divergências nas distribuições de frequência são mais evidentes. O mesmo procedimento foi repetido para os temas “educação”, “previdência” e “mulher”, respectivamente, nas figuras 5.3, 5.4 e 5.5.




Figura 5.2: Distribuição do tema “corrupção” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.




Figura 5.3: Distribuição do tema “educação” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.




Figura 5.4: Distribuição do tema “previdência” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.




Figura 5.5: Distribuição do tema “mulher” em 2016: (a) inclui dias com ocorrência zero; (b) desconsidera dias com ocorrência zero.

A inspeção visual das distribuições de frequência traz esclarecimento adicional às técnicas exploratórias discutidas no Capítulo 4 e se apresenta como instrumento complementar de análise. Contudo, um modelo inferencial não se pode apoiar apenas em percepções visuais e necessita de método bem definido para se avaliar adequadamente o quanto as distribuições de frequências de dois conjuntos de dados se assemelham. Testes de hipótese são o próximo passo nessa direção.

Pela observação simples das distribuições ilustradas nas figuras de 5.2 a 5.5 é possível constatar que não possuem aparência simétrica ou formato de sino, não se constituindo em distribuições normais (o que pode ser confirmado por testes de normalidade). Em geral, a distribuição de termos no discurso não é normal. Portanto, testes não paramétricos¹⁸ são necessários. No presente estudo, a estatística qui-quadrado, que confronta um evento observado com o valor esperado para esse evento, desponta como alternativa viável.

Os temas utilizados nesta seção para o exercício de observação das frequências foram os decorrentes da aplicação da LDA no capítulo anterior. Porém, uma verificação mais consistente deve considerar os temas mais frequentes num dado período, comum a dois partidos sob análise, e compará-los segundo a estatística qui-quadrado.

5.2 TESTE QUI-QUADRADO

Qui-quadrado, simbolizado por χ^2 , é um teste não paramétrico, cujo princípio básico é comparar proporções, isto é, as possíveis divergências entre as frequências observadas e esperadas para um certo evento.

Podemos contar os incidentes de um evento e comparar os resultados obtidos a partir dos dados reais com os resultados esperados para o evento. Suponha que 27 pessoas fossem perguntadas sobre a preferência partidária entre PT, PSDB ou PMDB. Caso não existisse preferência definida, esperaríamos que 9 respondessem PT, 9 PSDB, e 9 PMDB. Usamos, então, um teste qui-quadrado para comparar o que observamos (real) com o que esperamos. Se nossa amostra indicar que 2 gostam do PT, 20 do PSDB, e 5 do PMDB, podemos afirmar,

¹⁸ Teste não paramétrico é aquele que não depende de parâmetros populacionais como, por exemplo, média e variância.

com algum grau de confiança, que mais pessoas simpatizam com o PSDB. Se nossa amostra indicar que 8 preferem o PT, 10 o PSDB, e 9 o PMDB, então não é adequado afirmar que o PSDB é o preferido.

Em outras palavras, o teste qui-quadrado nos diz com quanta certeza os valores observados podem ser explicados pela teoria em estudo.

A aplicação do teste qui-quadrado pressupõe o atendimento às seguintes condições:

- os grupos devem ser independentes;
- os itens de cada grupo devem ser selecionados aleatoriamente;
- as observações devem ser frequências ou contagens;
- cada observação deve pertencer a uma e somente uma categoria (ou classe); e
- a amostra deve ser relativamente grande (ao menos 5 observações em cada célula e, no caso de poucos grupos, pelo menos 10).

A forma de cálculo do teste qui-quadrado foi proposta por Karl Pearson, em 1900, e consiste na aferição do desvio entre proporções observadas (resultado de um experimento) e esperadas (distribuição esperada para o fenômeno), representada por

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \quad (3)$$

onde O_i é a frequência observada e E_i a frequência esperada para cada uma das k classes.

As frequências observadas são obtidas diretamente dos dados das amostras, enquanto que as frequências esperadas são estimadas a partir de conceitos teóricos estabelecidos ou de conhecimento adquirido previamente sobre os eventos.

5.2.1 Distribuição Qui-quadrado

Se repetirmos continuamente o experimento que consiste em selecionar aleatoriamente amostras de uma população, efetuarmos a contagem das observações respectivas a cada uma

das k classes contidas na amostra e calcularmos a estatística χ^2 , conforme a Equação (3), encontramos a distribuição qui-quadrado.

A curva de densidade de probabilidade para a distribuição χ^2 depende do número de graus de liberdade, onde $gl = k - 1$. A Figura 5.6 ilustra a distribuição para distintos valores de k .




Figura 5.6: Distribuição χ^2 para distintos valores de k .

A partir das curvas de densidade de probabilidade da Figura 5.6, as hipóteses nula e alternativa podem ser formuladas:

H_0 : As frequências observadas não diferem das frequências esperadas, isto é, não existe diferença entre as frequências (contagens) dos grupos.

H_1 : As frequências observadas são diferentes das frequências esperadas, portanto existe diferença entre as frequências dos grupos.

Como a área sob a curva da distribuição χ^2 é igual a 1, o teste de hipótese pode ser feito como na curva normal, ou seja, estabelecendo-se a probabilidade da região crítica (ou nível de significância α) em que se rejeita H_0 . No ambiente R, utilizamos a função **pchisq** para determinar a probabilidade de um dado valor χ^2 para k classes.

5.2.2 Tabela de Contingência

O teste χ^2 pode ser aplicado nos casos em que não se dispõe de uma teoria que permita efetuar o cálculo das classes esperadas. Nesses casos, a essência do teste consiste em comparar as frequências observadas com as frequências esperadas quando se observa a condição de independência de grupos. Se a diferença entre as frequências observadas e esperadas for suficientemente grande, então a hipótese nula de independência é rejeitada:

H_0 : Não há associação entre os grupos, ou seja, as variáveis categóricas são independentes.

H_1 : Há associação entre os grupos, ou seja, as variáveis categóricas são dependentes.

Esse tipo de situação ocorre quando desejamos verificar se uma determinada característica se distribui igualmente entre grupos, como sexo, classe social, grupo racial, faixa etária, localização geográfica, etc. Portanto, não há como prever um valor esperado teórico, mas há como estimar um valor esperado a partir da relação cruzada dos grupos. Esse método é denominado **tabela de contingência**.

A estatística χ^2 é a soma das diferenças entre valores observados e esperados em todas as células da tabela, escaladas pela magnitude dos valores esperados, da seguinte forma:

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \quad (4)$$

onde i representa as linhas e j as colunas da tabela, O_{ij} é o valor observado na célula (i, j) e E_{ij} é o valor esperado. Os valores de E_{ij} são computados a partir das probabilidades marginais, isto é, a partir dos totais de linhas e colunas convertidos em proporções.

Suponha que 150 pessoas tenham sido consultadas na pesquisa de preferência por partidos e que queiramos testar a dependência da variável partido com o grupo sexo. A tabela de contingência está representada na Tabela 5.1.

Tabela 5.1: Tabela de Contingência: pesquisa de opinião sobre preferência partidária classificada por sexo.

Partido	Sexo		Total
	Masculino	Feminino	
PT	25	45	70
PSDB	15	25	40
PMDB	10	30	40
Total	50	100	150

FONTE: Elaborado pelo autor.

Por definição, dois eventos são independentes quando a probabilidade de ambos acontecerem juntos é igual ao produto das probabilidades de cada evento acontecer individualmente:

$$P(AB) = P(A)P(B) \quad (5)$$

Então, o valor esperado para o acontecimento conjunto de dois eventos independentes é dado por

$$E(AB) = P(A)P(B) * N \quad (6)$$

onde N é o número total de eventos.

Por exemplo, o valor esperado para a célula (1, 1) (preferência pelo PT, sexo masculino) é a probabilidade marginal do partido escolhido ser o PT, multiplicada pela probabilidade marginal da escolha ter sido feita pelo sexo masculino, multiplicada por N , ou seja

$$\frac{25 + 45}{150} * \frac{25 + 15 + 10}{150} * 150 = \frac{70 * 50}{150} \approx 23,3$$

Portanto, se a preferência pelo PT independe de o sexo do entrevistado ser masculino, então o valor esperado é de aproximadamente 23,3 ocorrências para essa combinação. A Tabela 5.2 mostra a tabela de contingência com os respectivos valores esperados.

Tabela 5.2: Tabela de Contingência e valores esperados: pesquisa de opinião sobre preferência partidária classificada por sexo.

Partido	Sexo		Total	Valor esperado	
	Masculino	Feminino		Masculino	Feminino
PT	25	45	70	$(70*50)/150 \approx 23,3$	$(70*100)/150 \approx 46,7$
PSDB	15	25	40	$(40*50)/150 \approx 13,3$	$(40*100)/150 \approx 26,7$
PMDB	10	30	40	$(40*50)/150 \approx 13,3$	$(40*100)/150 \approx 26,7$
Total	50	100	150		

FONTE: Elaborado pelo autor.

A partir da Equação 4, o valor de χ^2 é dado por

$$\chi^2 = \frac{(25-23,3)^2}{23,3} + \frac{(45-46,7)^2}{46,7} + \frac{(15-13,3)^2}{13,3} + \frac{(25-26,7)^2}{26,7} + \frac{(10-13,3)^2}{13,3} + \frac{(30-26,7)^2}{26,7} \approx 1,74$$

A probabilidade de χ^2 ser aproximadamente 1,74 pode ser determinada pela função **pchisq**, do R, onde o número de graus de liberdade é dado por

$$gl = (\text{número de linhas} - 1) * (\text{número de colunas} - 1) \quad (7)$$

donde se encontra $p \approx 0,42$. Logo, o teste falha em rejeitar H_0 e, portanto, infere-se que as variáveis partido e sexo são independentes.

A função `qui_quadrado_cont` (script “22_TesteHipotese.R”) foi escrita para efetuar o teste qui-quadrado em tabelas de contingência. As seções que seguem fazem uso do teste qui-quadrado para a comparação do discurso parlamentar.

5.3 COLLOCATIONS

Muito embora o princípio da análise do saco-de-palavras desconsidere a ordem em que as palavras estão dispostas no texto, faz-se necessário investigar o papel dessa ordem na determinação de contexto semântico. Isso porque, se é razoável considerar que a comparação de discursos com base nas palavras mais frequentes é uma medida da similaridade dos temas abordados no discurso, também é razoável considerar que esses tópicos são mais bem

representados por bigramas do que por termos isolados, uma vez que bigramas carregam mais informação.

Portanto, no sentido de se mensurar o quanto um discurso (ou um *corpus* de discursos) se assemelha a outro por meio de bigramas, é importante verificar se os termos de um bigrama acontecem juntos por acaso ou por alguma razão de dependência que expresse uma forma convencional de dizer as coisas, isto é, que esteja inserida em um contexto semântico. Expressões de duas ou mais palavras que correspondam a uma forma convencional de dizer as coisas são chamadas de colocações, ou *collocations* (MANNING e SCHÜTZE, 1999). O teste qui-quadrado pode ser utilizado para avaliar se duas palavras constituem uma *collocation* ou se ocorrem ao acaso.

Por exemplo, a Tabela 5.3 mostra a distribuição dos termos “ensino” e “médio”, para análise do bigrama “ensino medio”, onde w_1 e w_2 se referem, respectivamente, à primeira e à segunda palavra do bigrama.

Tabela 5.3: Tabela de contingência: distribuição dos termos “ensino” e “médio” para análise do bigrama “ensino medio”.

	$w_1 = \text{ensino}$	$w_1 \neq \text{ensino}$
$w_2 = \text{medio}$	478 (ensino medio)	53 (p.e., oriente medio)
$w_2 \neq \text{medio}$	269 (p.e., ensino superior)	32.638

Nota: frequências aferidas a partir dos discursos do PT em 2016.

Aplicando o teste qui-quadrado (função `qui_quadrado_cont`) para a tabela de contingência (Tabela 5.3), encontramos $\chi^2 \approx 28,75$ e $p \approx 0.0000000821$, o que significa que H_0 deve ser rejeitada, ou seja, as palavras “ensino” e “medio” não ocorrem juntas ao caso. São, portanto, dependentes e constituem uma *collocation*.

A função `testa_collocations` (script “22_TesteHipotese.R”) foi escrita para verificar se os bigramas mais frequentes do discurso são ou não *collocations*. As tabelas 5.4 e 5.5

ilustram, respectivamente, os testes para os 10 bigramas mais frequentes nos discursos do PT e PSDB, no ano de 2016.

Tabela 5.4: Teste qui-quadrado para a verificação de *collocations* nos 10 bigramas mais frequentes nos discursos do PT, no ano de 2016.

bigrama	χ^2	<i>p</i> collocation	
1 ensino medio	19.037,83	0,00	Sim
2 reforma previdencia	4.285,99	0,00	Sim
3 combate corrupcao	3.575,85	0,00	Sim
4 supremo tribunal	11.153,777	0,00	Sim
5 direito humano	1.388,03	8,40e-298	Sim
6 operacao lavajato	8.617,12	0,00	Sim
7 saude educacao	283,69	1,18e-57	Sim
8 reforma ensino	804,56	5,51e-171	Sim
9 meios comunicacao	5.977,17	0,00	Sim
10 policia militar	1.168,71	3,84e-256	Sim

Tabela 5.5: Teste qui-quadrado para a verificação de *collocations* nos 10 bigramas mais frequentes nos discursos do PSDB, no ano de 2016.

bigrama	χ^2	<i>p</i> collocation	
1 ensino medio	13.977,24	0,00	Sim
2 reforma previdencia	4.648,97	0,00	Sim
3 supremo tribunal	7.863,17	0,00	Sim
4 direito humano	1.355,18	1,16e-296	Sim
5 evaristo arns	18.218,90	0,00	Sim
6 combate corrupcao	2.558,66	0,00	Sim
7 banco central	7.438,58	0,00	Sim
8 operacao lavajato	7.338,96	0,00	Sim
9 abuso autoridade	72.397.713	0,00	Sim
10 juiz promotor	3389,96	0,00	Sim

Observa-se, das tabelas 5.4 e 5.5, que os bigramas não acontecem ao acaso, são *collocations* e, portanto, podem ser utilizados na comparação dos discursos.

5.4 SIMILARIDADE DE CORPUS

Kilgarriff e Rose (1998) propuseram uma aplicação interessante para a estatística χ^2 : servir como métrica da similaridade de dois *corpus*. Em seu estudo, os autores compilaram uma tabela de n linhas por 2 colunas (com $n = 500$) onde cada coluna correspondia à frequência das palavras mais frequentes, comuns aos dois *corpus* sendo comparados. A Tabela 5.6 contém uma representação esquemática dessa concepção, utilizando os *corpus* de discursos do PT e PSDB em 2016.

Tabela 5.6: Palavras mais frequentes comuns aos *corpus* de discursos do PT e PSDB em 2016.

	palavra	freq. PT	freq. PSDB
1	aborto	268	155
2	absolutamente	135	68
3	absurdo	160	77
4	abuso	234	163
5	acabar	166	87
6	acao	677	265
7	aceitar	156	81
8	acesso	242	107
9	acidente	151	57
10	acima	234	93
...			
n			

Para cada uma das n palavras mais frequentes é necessário calcular o número de ocorrências esperadas (valor esperado) em cada *corpus*, no intuito de verificar se ambos podem considerados amostras aleatórias de uma mesma população. Dados os tamanhos N_1 e N_2 , dos *corpus* 1 e 2, e as frequências observadas o_{w1} e o_{w2} da palavra w nos respectivos *corpus*, então, o valor esperado para essa palavra no *corpus* 1 é dado por

$$e_{w1} = \frac{N_1 * (o_{w1} + o_{w2})}{N_1 + N_2} \quad (8)$$

e, no *corpus* 2, por

$$e_{w2} = \frac{N_2 * (o_{w1} + o_{w2})}{N_1 + N_2} \quad (9)$$

Conhecendo-se os valores observados e esperados, então χ^2 pode ser determinado pela Equação 3. A falha em rejeitar H_0 significa que as frequências observadas não diferem das esperadas, isto é, não existe diferença entre os *corpus*.

A função `corpus_similaridade` (script “22_TestesHipotese.R”) implementa esse procedimento e estima os valores de χ^2 e p . A partir disso, a proposta de Kilgarriff e Rose (1998) foi inicialmente testada para combinações dos partidos PT, PSDB, PMDB, PSOL, PCDoB e PTB, cujos *corpus* do ano de 2016 foram comparados dois a dois, por meio dos unigramas e bigramas (estes, testados para *collocations*). A Tabela 5.7 apresenta os resultados (script “23_ExecutaTestesHipotese.R”).

Tabela 5.7: Métrica χ^2 para similaridade de *corpus*: partidos PT, PSDB, PMDB, PSOL, PCdoB e PTB; ano 2016.

Partido 1	Partido 2	Unigrama			Bigrama (<i>collocation</i>)		
		χ^2	p	H_0	χ^2	p	H_0
PT	PSDB	8.914,39	0,00	rejeita	2.386,57	7,24e-302	rejeita
PT	PMDB	7.466,75	0,00	rejeita	1.836,77	1,67e-196	rejeita
PT	PSOL	18.330,52	0,00	rejeita	4.093,27	0,00	rejeita
PT	PCdoB	18.682,52	0,00	rejeita	4.217,40	0,00	rejeita
PT	PTB	16.375,93	0,00	rejeita	4.390,26	0,00	rejeita
PSDB	PMDB	280,85	1,00	aceita	165,68	1,00	aceita
PSDB	PSOL	5.230,37	0,00	rejeita	1.679,38	1,91e-221	rejeita
PSDB	PCdoB	5.531,61	0,00	rejeita	1.763,91	2,38e-238	rejeita
PSDB	PTB	6.848,77	0,00	rejeita	3.289,55	0,00	rejeita
PMDB	PSOL	6.669,80	0,00	rejeita	1.919,91	7,75e-277	rejeita
PMDB	PCdoB	6.959,11	0,00	rejeita	1.994,99	1,83e-292	rejeita
PMDB	PTB	7.816,19	0,00	rejeita	3.113,44	0,00	rejeita
PSOL	PCdoB	73,33	1,00	aceita	16,83	1,00	aceita
PSOL	PTB	1.621,29	1,35e-116	rejeita	708,59	8,29e-32	rejeita
PCdoB	PTB	1.443,21	1,32e-89	rejeita	648,03	8,91e-23	rejeita

Observa-se a similaridade de *corpus*, ou do discurso, nas combinações PSDB/PMDB e PSOL/PCdoB. Em análise preliminar, olhando sob um único prisma, isso parece razoável num ano em que o *impeachment* da presidenta Dilma dominou o cenário político, no qual partidos como PSDB e PMDB se aliaram à causa, ao passo que outros, como PSOL e PCdoB, posicionaram-se contrariamente. Observa-se, também, que o discurso do PT não se

assemelha ao de nenhum outro partido, talvez refletindo uma quebra da base governista diante dos inúmeros interesses que circundam o tema *impeachment*. Ou seja, são diversas as possibilidades de interpretação dos resultados quantitativos, que devem ser acompanhados de uma análise qualitativa dos fatos.

Portanto, no sentido de objetivar o estudo, são necessários critérios específicos capazes de isolar o ponto de investigação da influência de variáveis espúrias. Quando se busca identificar padrões do discurso que apontem traços de convergência ideológica, algumas questões precedem a análise: Qual a definição a ser considerada para ideologia? Qual a métrica para se aferir convergência ideológica? Qual o período para se efetuar as medições? Em que etapas da sessão plenária os fatores ideológicos, caso existam, poderiam ser revelados e por quê?

A seção seguinte é dedicada a responder tais questionamentos.

5.5 IDEOLOGIA POLÍTICO-PARTIDÁRIA E COALIZÃO

Neste trabalho não há a pretensão de se discutir os aspectos filosóficos do conceito “ideologia” em sua amplitude teórica, mas, tão somente, estabelecer um referencial pragmático para a observação comportamental dos agentes políticos, um recurso metodológico para a aplicação do método quantitativo com o propósito de se identificar eventos que possam, em certo nível, revelar alguma forma de afinidade, lealdade partidária e/ou coerência do discurso.

Eagleton (1997), argumentando que uma definição única de ideologia seria inútil diante da variedade de significados possíveis, apresentou uma lista das definições mais comuns. Dessa lista, alguns itens merecem destaque para o presente estudo: conjunto de crenças orientadas para a ação; corpo de ideias característico de um determinado grupo ou classe social; ideias que ajudam a legitimar um poder político dominante; pensamento de identidade; a conjuntura de discurso e poder.

Segundo Cancian (2007), em pesquisas empíricas, o termo “ideologia” é usado com o objetivo de “descrever o conjunto de ideias, valores ou crenças que orientam a percepção e

o comportamento dos indivíduos sobre diversos assuntos ou aspectos sociais, como, por exemplo, as opiniões e as preferências que os indivíduos têm sobre o sistema político vigente, a ordem pública, o governo, as leis, as condições econômicas e sociais, entre outros”.

No escopo deste trabalho, de forma simplificada, a ampliação do conceito “ideologia” para “ideologia político-partidária” pode ser proposta como o conjunto de orientações políticas com o qual um partido se compromete. Ainda que esse conjunto sofra alterações com o tempo, deve refletir o compromisso do partido num dado contexto temporal. Olhando esse conceito sob a perspectiva das coalizões partidárias, pode parecer óbvio que essas associações deveriam ocorrer, por princípio, entre partidos que compartilhassem das mesmas orientações políticas, ou, ao menos, da maior parte delas. Assumindo essa premissa como verdadeira, poderíamos supor que dois partidos coligados pertenceriam à mesma ideologia político-partidária.

Contudo, a primeira teoria sobre o processo de formação de coalizões, desenvolvida pelo cientista político William H. Riker, não pressupunha proximidade ideológica (RIKER, 1962). Essa questão só foi proposta anos mais tarde por Robert Axelrod (AXELROD, 1970).

Rodrigues (2009, p. 27), em seu estudo sobre as bancadas partidárias na Câmara dos Deputados, discute a lógica ideológica das coligações partidárias sob duas vertentes defendidas por pesquisadores da área: por um lado, defende-se que as coligações partidárias recebem avaliação negativa da opinião pública por unirem, muitas vezes, legendas ideológica e programaticamente discrepantes, num cenário de acentuada migração partidária, revelando, na verdade, a falta de programas e ausência de compromisso ideológico; por outro lado, acredita-se que, embora haja coligações inconsistentes, a maioria obedece à lógica da afinidade ideológica.

Reisman (2016) destaca que a formação das nossas coalizões políticas está localizada temporalmente em um momento pré-eleitoral, quando se negociam as alianças estratégicas entre os partidos políticos para as eleições majoritárias e proporcionais. Ao estudar as coalizões eleitorais lideradas pelo PT em campanhas presidenciais, o autor constatou que, ainda que os critérios de formação pela ideologia pareçam ser dominantes, essa suposta convergência ideológica não impediu a movimentação das bandeiras das coalizões da

esquerda para o centro, mostrando que a ideologia se submete à lógica eleitoral. Tais coalizões, ao longo do tempo, passaram por drástica redução na carga ideológica e adotaram programas eleitorais genéricos e abstratos. Em sua vertente pragmática, essas coalizões abandonaram defesas de pontos polêmicos e aproximaram-se do centro do eixo esquerda-direita.

Com base nos aspectos abordados, alguns pontos podem ser estabelecidos para guiar os próximos passos desta pesquisa:

1. por princípio, toda coalizão é fundada no conceito proposto de ideologia político-partidária; logo, deve-se esperar alto grau de similaridade entre os discursos de parlamentares pertencentes a partidos coligados;
2. um indicador para medir identidade ideológica deve ser capaz de captar o comportamento de todo um grupo de partidos; propõe-se que a probabilidade média das estatísticas χ^2 determinadas entre os discursos dos partidos de um grupo, tomados dois-a-dois, seja a base desse indicador;
3. considerando que a composição das coalizões se submete à lógica eleitoral, o indicador de identidade ideológica pode ser aferido ano-a-ano, com vistas a se comparar as variações entre anos eleitorais e não eleitorais.

Resta em aberto a questão sobre as etapas da sessão plenária que poderiam favorecer um debate de caráter ideológico, menos influenciado pelas pressões das votações de proposições e dos humores políticos acentuados.

Sobre esse aspecto, Moreira (2016) identificou que os discursos proferidos no Pequeno Expediente¹⁹ não apresentam concentração de temas, “havendo indícios de que tal estratégia é orientada especialmente pela quantidade de discursos proferidos e pela ideologia da legenda pela qual o parlamentar foi eleito”. Acrescenta o autor que “há entre os parlamentares diferenças de foco temático” e que “tal diferença sofre a influência do percentual de votos recebidos, da ideologia da legenda partidária pela qual o parlamentar foi eleito”.

¹⁹ Primeira parte da sessão ordinária do Plenário, tem duração máxima de 60 minutos e é destinado às comunicações de parlamentares previamente inscritos. RICD, Arts. 79 A 81.

Esse fenômeno pode ser decorrente da liberdade que o parlamentar tem durante o Pequeno Expediente, podendo discursar sobre assuntos livres por até 5 (cinco) minutos. Ainda segundo Moreira (2016), “muitos deputados passam o mandato inteiro sem falar nas votações e comissões, mas no Pequeno Expediente quase todos discursam”, revelando que, nas legislaturas de número 51 a 54, 88% dos deputados realizaram ao menos um discurso no Pequeno Expediente, com uma média de 59 falas por deputado federal.

Diante desses achados, não há dúvida sobre a inclusão do Pequeno Expediente na análise. Entretanto, optou-se, aqui, por incluir, também, os discursos proferidos no Grande Expediente²⁰, visto que essa fase guarda duas semelhanças com a primeira: o deputado manifesta a intenção de discursar por meio de inscrição; existe liberdade para o tema do discurso.

5.6 ÍNDICE DE IDENTIDADE IDEOLÓGICA

O indicador aqui proposto, batizado como Índice de Identidade Ideológica, se destina a mensurar o grau de similaridade do discurso de um grupo de partidos afins. Como já mencionado, a ideia consiste em determinar a probabilidade média das estatísticas χ^2 encontradas na comparação dos discursos de partidos pertencentes a um dado grupo, tomados dois-a-dois.

Pelo pressuposto da ideologia político-partidária assumido na Seção 5.5, deve-se esperar que esse indicador tenha valor muito próximo de 1 (um) quando mensurado sobre partidos de uma mesma coligação. Por analogia, o mesmo princípio, quando aplicado a partidos com orientações políticas opostas, deve produzir valores próximos de zero.

Para fins deste estudo, foram efetuadas três medições distintas do indicador, ano-a-ano, no período de 2001 a 2015, a partir dos discursos proferidos durante o Pequeno Expediente e o Grande Expediente: a primeira, considera somente os partidos pertencentes à coalizão de governo (ou base governista); a segunda, considera somente os partidos não pertencentes à

²⁰ Fase da sessão plenária que sucede à do Pequeno Expediente com duração improrrogável de cinquenta minutos. Destina-se ao pronunciamento de parlamentares inscritos por até vinte e cinco minutos para cada orador, incluídos aí os eventuais apartes concedidos. RICD, Art. 66.

coalizão de governo (aqui definido, de forma geral, como oposição); a terceira, estima a similaridade do discurso entre partidos pertencentes e os não pertencentes à coalizão de governo. Os dados sobre as composições das coalizões de governo a cada ano foram extraídos da Base de Dados Legislativos²¹ do Cebrap (Centro Brasileiro de Análise e Planejamento). Os códigos de programação estão disponíveis no script “23_ExecutaTestesHipoteses.Rmd”.

Para cada ano do período foi gerada uma matriz de similaridade, como a da Tabela 5.8, que retrata os valores estimados para o ano de 2003. Os partidos grafados em caixa alta correspondem à coalizão governista.

Tabela 5.8: Matriz de similaridade do discurso para o ano de 2003: i_{coa} é o índice de identidade ideológica para a coalizão governista; i_{opo} é o índice de identidade ideológica para a oposição; i_{dif} é o índice de identidade ideológica quando grupos diferentes são comparados.

	pfl	PCdoB	PDT	pmd b	pp	PPS	PR	prona a	PSB	psc	psd b	PT	PT B	PV	i_{coa}	i_{opo}	i_{dif}
Pfl	1,00	0,00	0,00	0,97	0,00	0,00	0,00	0,00	0,00	0,00	0,68	0,00	0,00	0,00	—	0,33	0,00
PCdoB	0,00	1,00	1,00	0,00	1,00	1,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	1,00	0,43	—	0,17
PDT	0,00	1,00	1,00	0,00	1,00	1,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	1,00	0,43	—	0,17
pmdb	0,97	0,00	0,00	1,00	0,00	0,00	0,00	0,00	0,00	0,00	1,00	0,00	0,00	0,00	—	0,39	0,00
pp	0,00	1,00	1,00	0,00	1,00	1,00	1,00	0,00	1,00	0,00	0,00	0,00	0,00	0,00	—	0,00	0,62
PPS	0,00	1,00	1,00	0,00	1,00	1,00	1,00	0,00	1,00	0,00	0,00	0,00	0,00	0,00	0,57	—	0,17
PR	0,00	0,00	0,00	0,00	1,00	1,00	1,00	0,00	1,00	0,00	0,00	0,00	1,00	0,00	0,43	—	0,17
prona	0,00	0,00	0,00	0,00	0,00	0,00	0,00	1,00	0,00	0,74	0,00	0,00	0,00	1,00	—	0,15	0,13
PSB	0,00	0,00	0,00	0,00	1,00	1,00	1,00	0,00	1,00	0,00	0,00	0,00	0,95	0,00	0,42	—	0,17
psc	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,74	0,00	1,00	0,00	0,00	0,00	0,00	—	0,15	0,00
psdb	0,68	0,00	0,00	1,00	0,00	0,00	0,00	0,00	0,00	0,00	1,00	0,00	0,00	0,00	—	0,34	0,00
PT	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	1,00	0,00	0,00	0,00	—	0,00
PTB	0,00	0,00	0,00	0,00	0,00	0,00	1,00	0,00	0,95	0,00	0,00	0,00	1,00	0,00	0,28	—	0,00
PV	0,00	1,00	1,00	0,00	0,00	0,00	0,00	1,00	0,00	0,00	0,00	0,00	0,00	1,00	0,29	—	0,17
Média															0,36	0,23	0,12

Nota: os partidos grafados em caixa alta correspondem à coalizão governista; as células de cruzamento dos partidos representam a probabilidade da estatística χ^2 resultante da comparação dos respectivos partidos; as células em azul destacam os termos utilizados na respectiva linha para a estimativa do índice de identidade ideológica da coalizão governista (i_{coa}); as células em salmão destacam os termos utilizados na respectiva linha para a estimativa do índice de identidade ideológica da oposição (i_{opo}); as células na cor verde destacam os termos utilizados na respectiva linha para a estimativa do índice de identidade ideológica dos partidos de grupos diferentes (i_{dif}).

A Figura 5.7 ilustra os resultados encontrados para o período de 2001 a 2015, destacando os respectivos governos da época.

²¹ <http://neci.fflch.usp.br/node/506>




Figura 5.7: Índice de Identidade Ideológica no período de 2001 a 2015.

5.7 ANÁLISE

Mais uma vez, chegamos à uma fase da pesquisa que nos remete à Figura 2.1, do Capítulo 2, no ponto em que as novas informações extraídas devem ser examinadas na busca por intuições, descobertas, resultados ou recomendações. Não há a pretensão de se fazer uma análise exaustiva, mas, apenas, uma correlação dos resultados da Figura 5.7 com alguns fatos possivelmente explicativos de cada fase de governo, de forma a se avaliar o potencial analítico do indicador proposto.

Um primeiro padrão observado é o da ascendência do indicador da base governista nos anos eleitorais (2002, 2006, 2010 e 2014), seguida por queda no ano posterior ao da eleição. Esse comportamento tende a confirmar a argumentação de Reisman (2016) de que a ideologia se submete à lógica eleitoral. Movimento semelhante é observado no indicador de oposição, exceto para o ano 2002, ano em que Lula seria eleito para o seu primeiro mandato à Presidência da República. Nessa ocasião, quando Lula começou a crescer nas pesquisas de opinião de voto, um clima de insegurança se espalhou nas áreas política e econômica, sob a desconfiança de que o país poderia falir. Lula se viu obrigado a assinar texto que ficou conhecido como Carta aos Brasileiros²², no qual se disse disposto a discutir com o presidente Fernando Henrique Cardoso uma agenda de resposta à crise financeira, o que desagradou setores da esquerda e políticos do próprio PT, oposição à época. Esse fato pode estar refletido no indicador.

Importante ressaltar que no experimento da Figura 5.7, o termo oposição foi utilizado conscientemente de forma ampla, sendo classificado como de oposição qualquer partido não pertencente à coalizão de governo, o que é uma simplificação demasiada. Não se trata, portanto, de uma coalizão de oposição, mas de partidos não formadores da base, dos quais não se deve, em princípio, esperar uma convergência ideológica. Apenas para citar um exemplo, esse critério faz com que, em 2002, o PPS apareça no mesmo pacote do PT. No entanto, sabe-se que naquele ano o candidato à presidência pelo PPS, Ciro Gomes, era, talvez, o mais ferrenho crítico de Lula. De toda forma, essa convergência aparece nos demais anos eleitorais.

²² <http://www1.folha.uol.com.br/folha/brasil/ult96u33908.shtml>

Ainda no período FHC, verifica-se forte convergência da base em 2001 e uma situação única de total convergência em 2002. Valer observar que nessa época a coalizão era composta por somente 4 (quatro) partidos, praticamente metade da quantidade que viria a compor as bases dos governos posteriores. Natural aceitar que é mais fácil de se conseguir identidade entre 4 (quatro) do que entre 8 (oito). Quando os diferentes (base e não base) são comparados, nenhum traço de identidade é encontrado.

No período Lula I, os dois primeiros anos mostram queda dos indicadores de base e de oposição, talvez decorrente do fato de que um partido que sempre fora oposição (PT), agora estava no comando e encontraria resistências na própria base (com oito partidos em 2003 e nove partidos em 2004) ao apoiar políticas neoliberais; enquanto que, por outro lado, o partido que comandara o país nos últimos 8 (oito) anos (PSDB), agora assumia, segundo Bezerra (2012), uma oposição programática, de grau oposicionista menor, mas com possibilidade de vitórias em determinadas matérias. Isso também explica o crescimento do indicador dos diferentes, uma vez que, de acordo com a mesma autora, partidos como PSDB e DEM adotaram pontualmente a estratégia de colaborar com o executivo. Em 2005, o indicador de base registra o menor valor no período, em meio a denúncias de corrupção que deflagraram o escândalo do Mensalão, envolvendo partidos da coalizão governista. Nesse mesmo ano, o indicador de oposição cresce, como que decorrente de um resgate de identidade da oposição em torno do discurso de combate à corrupção. Por fim, em 2006, a lógica eleitoral prevalece e tanto base quanto oposição afinam o discurso num movimento crescente de ambos os indicadores, com prevalência para o indicador de base.

O período Lula II mostra certa estabilidade do indicador de base, com pico em 2010, ano eleitoral. Superadas as desconfiças em relação ao primeiro governo Lula, amortecidos os impactos do Mensalão, diante de um cenário de recuperação do crescimento e de economia estável, tudo isso associado à habilidade política do presidente, parece razoável que não tenha havido grandes variações de identidade no discurso da base. O indicador de oposição, após registrar mínimo em 2007, tem ascendência linear até 2010. O indicador dos diferentes aponta para a similaridade entre os discursos da base e oposição no ano eleitoral, o que condiz com o cenário de alta popularidade do presidente Lula ($\approx 87\%$) e de alto índice de aprovação do governo ($\approx 80\%$). Não seria prudente à oposição pautar o discurso na crítica a Lula, razão pela qual o mote da campanha eleitoral do PSDB foi “O Brasil pode mais”, com

as expressões “nós vamos fazer mais” e “podemos fazer mais e melhor” frequentemente repetidas em seus programas eleitorais.

O primeiro ano do período Dilma I repete a tendência natural de queda dos índices de identidade ideológica. Mas a queda do indicador de base não se resumiria a uma tendência natural. A conjuntura internacional se tornou desfavorável no plano econômico, com baixo crescimento mundial, afetando, também, a economia brasileira. Diante de cenário como esse, a capacidade de articulação política do líder do Executivo é requisito fundamental para se contornar as dificuldades e aprovar as medidas necessárias. Contudo, no campo da habilidade política, a presidente Dilma se mostrou ineficaz, marcada pela incapacidade de dialogar com os atores políticos. Por muitas vezes, deixara de receber deputados e senadores do próprio partido, o que levou o governo a perder votações e espaço para pautar agendas no Congresso Nacional. Em 2012, mesmo sem grandes lançamentos de programas sociais ou números robustos na economia, a popularidade do governo e a avaliação de Dilma bateram recordes, o que, provavelmente, reforçara o perfil autoritário da presidente. Nesse mesmo ano, o indicador de base atingiu nível inferior ao de 2005, ano do Mensalão. O indicador de oposição também apresentou queda, um pouco menos acentuada. A partir de 2013, os três índices retomam o caminho da lógica das eleições, no qual o indicador de oposição apresenta crescimento expressivo, alcançando valor máximo em 2014, reflexo de uma disputa eleitoral acirrada em que a reeleição de Dilma se deu por diferença de apenas 3,3% dos votos válidos.

No único ano mensurado para o período Dilma II, confirma-se, mais uma vez, a queda dos indicadores. Esse fenômeno decorre, possivelmente, de ajustes naturais motivados pelas novas configurações de mandatos nas esferas municipal, estadual e federal.

Neste exercício, testou-se o potencial analítico do Índice de Identidade Ideológica proposto, que mede a similaridade do discurso de partidos pertencentes a determinado grupo. O comportamento dos indicadores de base, oposição e dos diferentes, no período de 2001 a 2015, mostrou-se coerente com fatos que marcaram a história política nessa linha do tempo, sugerindo que o índice possui utilidade analítica para a explicação desses fatos, o que constitui um achado desta pesquisa. O capítulo seguinte aplica e avalia técnicas de aprendizagem de máquina como recursos de análise do discurso.

6 APRENDIZAGEM DE MÁQUINA

O cientista da computação Arthur Lee Samuel, um pioneiro no campo da inteligência artificial, descreveu o conceito de aprendizagem de máquina (*machine learning*) como o “campo de estudos que provê aos computadores a capacidade de aprender, sem ser explicitamente programados” (SAMUEL, 1959).

Diversos tipos de algoritmos de aprendizagem de máquina são utilizados para descobrir padrões em grandes quantidades de dados. De forma ampla, esses diferentes algoritmos podem ser classificados em dois grupos que definem a forma como o computador “aprende” com os dados para fazer previsões: aprendizagem supervisionada e não supervisionada.

A aprendizagem supervisionada é a mais usada e inclui técnicas como regressão linear e logística, classificação multiclasse e máquinas de vetores de suporte. O aprendizado supervisionado é assim denominado porque requer que as possíveis saídas do algoritmo sejam previamente conhecidas e que os dados usados para treinar o algoritmo estejam rotulados com respostas corretas.

Por outro lado, o aprendizado automático sem supervisão está mais alinhado com o que se costuma denominar de verdadeira inteligência artificial, ou seja, quando um computador pode aprender a identificar processos e padrões complexos sem a intervenção humana para fornecer orientação ao longo do caminho. Algoritmos sem supervisão incluem técnicas de agrupamento de k-means, análise de componente principal e regras de associação.

De forma pragmática, enquanto que um algoritmo de classificação supervisionado aprende, por exemplo, a atribuir a um discurso o rótulo do partido do parlamentar que o proferiu, sua contraparte não supervisionada analisará as semelhanças entre discursos e os separará em grupos, atribuindo seu próprio rótulo a cada grupo.

No Capítulo 4, seção 4.4.2, técnicas não supervisionadas de classificação por clusterização e modelo de tópicos (LDA) foram apresentadas. Neste capítulo é abordado o método de aprendizagem supervisionada de Naive Bayes (ZHANG, 2009) para a classificação do discurso parlamentar. O módulo **sklearn** (*scikit-learn*) escrito para a linguagem Python 3.6 foi utilizado para o teste dos algoritmos.

6.1 MÉTODO DE NAIVE BAYES

A classificação é uma questão fundamental na aprendizagem de máquina e mineração de dados. Na classificação, o objetivo do algoritmo de aprendizagem é construir um classificador a partir de um conjunto de dados de treinamento com etiquetas de classe (ZHANG, 2009).

Transcrevendo a notação utilizada por Zhang (2009), tipicamente, um exemplo E é representado por uma tupla de valores $(x_1, x_2, \dots, x_n)$, onde x_i é i -ésimo o valor da variável aleatória X . Seja C uma variável de classe binária e c um de seus possíveis valores: 1, para a classe positiva, e 0, para classe negativa. Um classificador é uma função que atribui um rótulo de classe a um dado exemplo E . Sob a perspectiva das probabilidades, de acordo com a Regra de Bayes, a probabilidade de um exemplo $E = (x_1, x_2, \dots, x_n)$ ser da classe c é dada por

$$p(c|E) = \frac{p(E|c)p(c)}{p(E)}. \quad (10)$$

E é classificado como da classe $C = 1$ se e somente se

$$f_b(E) = \frac{p(C=1|E)}{p(C=0|E)} \geq 1 \quad (11)$$

onde $f_b(E)$ é denominada Classificador Bayesiano.

Assumindo que, dado o valor c da classe C , os valores de x_n são independentes, isto é,

$$p(E|c) = p(x_1, x_2, \dots, x_n|c) = \prod_{i=1}^n p(x_i|c), \quad (12)$$

então, o resultado do classificador é dado por

$$f_{nb}(E) = \frac{p(C=1)}{p(C=0)} \prod_{i=1}^n \frac{p(x_i|C=1)}{p(x_i|C=0)}. \quad (13)$$

A função $f_{nb}(E)$ é denominada Classificador Bayesiano Ingênuo (Naive Bayesian Classifier), ou, simplesmente, função de Naive Bayes.

Quando os objetos de classificação são textos pertencentes a um *corpora*, geralmente se faz uso do método multinomial de Naive Bayes, que implementa o Classificador Bayesiano Ingênuo para a distribuição multivariada de dados. Nesses casos, os dados são tipicamente representados por vetores de frequência de palavras, ou, por matrizes TFIDF. A distribuição é parametrizada por vetores $\theta_y = (\theta_{y1}, \dots, \theta_{yn})$ para cada classe y , onde n é a quantidade de palavras, ou o tamanho do vocabulário do texto, e θ_{yi} é a probabilidade $p(x_i|y)$ da i -ésima palavra pertencente à amostra da classe y .

O parâmetro θ_y é estimado por uma versão suavizada da máxima verossimilhança²³, isto é, contagem de frequência relativa:

$$\hat{\theta}_{yi} = \frac{N_{yi} + \alpha}{N_y + \alpha n} \quad (14)$$

onde $N_{yi} = \sum_{x \in T} x_i$ é o número de vezes que a palavra i aparece em uma amostra da classe y nos dados de treinamento T , e $N_y = \sum_{i=1}^{|T|} N_{yi}$ é a quantidade total de palavras da classe y .

O fator α é conhecido como um hiperparâmetro, isto é, um parâmetro que controla a forma como o modelo funciona. O valor de $\alpha \geq 0$ explica recursos que não estão presentes nas amostras de aprendizado e previne a probabilidade zero nas estimativas: $\alpha = 1$ é chamado de suavização de Laplace; e $\alpha < 1$ é chamado de alisamento Lidstone. A otimização do hiperparâmetro é recomendada para uma classificação acurada.

6.2 CLASSIFICAÇÃO DO DISCURSO PARLAMENTAR

Esta seção descreve os passos da aprendizagem supervisionada efetuados para a classificação do discurso parlamentar. A ideia principal consiste em atribuir como rótulo do discurso o partido do parlamentar que o proferiu. Divide-se, então, o *corpus* sob análise em dois conjuntos de textos: um para treinamento, outro para teste. Com o propósito de se

²³ A estimativa por máxima verossimilhança (*maximum-likelihood estimation*) é um método para estimar os parâmetros de um modelo estatístico. De maneira geral, posto um conjunto de dados e um modelo estatístico, o método de máxima verossimilhança estima os valores dos diferentes parâmetros do modelo de maneira a maximizar a probabilidade dos dados observados.

otimizar a eficiência do algoritmo de predição, toda a fase de pré-processamento do *corpus* vista na seção 4.2 deve ser efetuada antes de se utilizar o módulo **sklearn** do Python.

Os testes do algoritmo de classificação foram executados sobre os discursos do PT e PSDB levantados no período de 2001 a 2015, utilizando-se o script “24_SupLearning_DadosTreinamentoTeste.R” para criar o arquivo “disc_classificacao.csv” na pasta “SupLearning”. A estrutura do arquivo está ilustrada no Quadro 6.1.

Quadro 6.1: Estrutura do arquivo de discursos do PT e PSDB no período de 2001 a 2015.

	ano	discurso	PT	PSDB
0	2001	nilson mour recentemente mundial alimentacao a...	1	0
1	2001	coriolano sale salario minimo realmente enigma...	1	0
2	2001	saulo pedrosa existe ditado popular considero ...	1	0
3	2001	lim eminente nilson mourao promulgacao constit...	1	0
4	2001	agnaldo muniz consumidor amargara aumento luz ...	1	0
5	2001	osmar terra manifestar preocupacao crise vivid...	1	0
...	...	...	...	...
47620	2015	cumprimentar conduz encerramento marcante ocor...	0	1
47621	2015	forte emocao sido emocao exagerada convivencia...	0	1
47622	2015	nacao vive apreensao economica sombra mexe nac...	0	1
47623	2015	familiar habito descongestionante nasal gota d...	0	1
47624	2015	venho saudar advogado oab atuacao democratica ...	0	1
47625	2015	assustadoramente cresce vitima carcere privado...	0	1

6.2.1 Experimento de classificação

Inicialmente, o *corpus* de discursos foi dividido em dados de treinamento e dados de teste, por meio da função **sklearn.model_selection.train_test_split**, na proporção de 2/3 e 1/3, respectivamente. Em seguida, foram contadas as frequências das palavras do *corpus*, utilizando-se a função **sklearn.feature_extraction.text.CountVectorizer**, que converte

uma coleção de textos para uma matriz de frequência de *tokens*, como um saco-de-palavras. A partir dessa matriz, um dicionário com o vocabulário dos dados de treinamento é criado, juntamente com uma matriz de frequência de *tokens* dos dados de teste, baseada no mesmo dicionário de treinamento. As matrizes de treinamento e de teste precisam usar um conjunto consistente de palavras, de forma que o modelo treinado possa compreender as entradas do teste. Esse processo está implementado no script Python “25_SupervisedLearning.ipynb”, escrito no ambiente Jupyter-Notebook.

Preparados os vetores de frequência, o algoritmo multinomial de Naive Bayes é executado por meio da função `sklearn.naive_bayes.MultinomialNB`, com acurácia aferida de 0,56 para $\alpha = 1$ (suavização de Laplace), ou seja, percentual de acerto de 56% na classificação dos discursos do teste. Esse modelo não tem potencial de predição maior do que o valor esperado para um classificador aleatório aplicado a grandes amostras, o que aponta a necessidade de ajuste.

Nesse sentido, variou-se o valor de α na expectativa de melhorar a acurácia do modelo, alcançando-se potencial de predição próximo a 70% para $\alpha \geq 8$ (Figura 6.1), o que representa ganho significativo. Mesmo assim, a taxa de acerto pode ser considerada insuficiente para aplicações críticas. Uma possível razão para o baixo desempenho é a escolha do rótulo que, no nível de partido, agrupa o estilo de parlamentares que se expressam e posicionam de formas distintas.




Figura 6.1: Acurácia do modelo multinomial de Naive Bayes para a classificação do discurso parlamentar como PT ou PSDB, de acordo com a variação do hiperparâmetro α .

6.2.2 Experimento de similaridade com algoritmo Naive Bayes

Neste experimento, o modelo multinomial de Naive Bayes é avaliado como possível método de aferição de similaridade do discurso. A proposta consiste em treinar o algoritmo com 100% dos discursos do *corpus* PT/PSDB, no período de 2001 a 2015, tomando-se o PT como referência de aprendizado. Então, os discursos dos demais partidos da coalizão de governo, para cada ano do período 2003/2015 (governo PT), são passados ao algoritmo como base de teste, com a indicação de que pertencem ao PT. A acurácia resultante mede o quanto os discursos dos partidos de coalizão foram reconhecidos pelo algoritmo de aprendizagem como sendo do PT, o que representa o grau de similaridade. A Figura 6.2 mostra os resultados desse modelo para $\alpha = 8$ (gerados pelo script “25_SupervisedLearning.ipynb”), comparados com o Índice de Identidade Ideológica estimado pela estatística χ^2 .




Figura 6.2: Acurácia de Naive Bayes ($\alpha = 8$) vs. estatística χ^2 : similaridade do discurso.

Verifica-se, na Figura 6.2, que as variações registradas pelo Índice de Identidade Ideológica coincidem em 2/3 dos casos (retângulos verdes) com o modelo de acurácia de Naive Bayes. Neste último, o valor de α foi definido como 8 (oito), em função dos resultados da Figura 6.1, e as variações observadas são mais sutis, menos sensíveis que as detectadas pela estatística χ^2 .

Isso decorre, provavelmente, das simplificações inerentes ao modelo que utiliza a acurácia de Naive Bayes: os discursos da coalizão são confrontados com o que o algoritmo aprendeu sobre o PT e nenhuma comparação é efetuada com os demais partidos da coalizão entre si; a escolha do rótulo no nível de partido não é suficiente para detectar as diferenças de estilo dos oradores; o fato de a base de testes não ter sido um subconjunto da base de treinamento pode ter produzido alguma inconsistência no conjunto de palavras.

De forma geral, o exercício desta seção representa ensaio investigatório que aponta para o possível uso dos recursos de aprendizagem supervisionada no estudo da similaridade do discurso. Contudo, a abordagem aqui proposta é ainda incipiente e não dispõe do mesmo grau de rigor inerente ao método χ^2 .

7 CONCLUSÕES E RECOMENDAÇÕES

O presente trabalho de pesquisa se desenvolveu com o objetivo principal de inserir abordagem prática à análise do discurso parlamentar, por meio de técnicas computacionais que fazem uso de três disciplinas: processamento de linguagem natural, estatística e aprendizagem de máquina. Não fez parte do escopo o detalhamento das teorias políticas em sua essência, mas, tão somente, a explanação teórica necessária para sustentar a aplicação dos métodos quantitativos com o devido rigor.

Os objetivos específicos, divididos em duas categorias, foram contemplados de acordo com os comentários que seguem.

Objetivos de suporte:

- (i) a identificação e aplicação das tecnologias disponíveis para o PLN, com enfoque nos pacotes de funcionalidades disponíveis para as linguagens R e Python;

Os recursos mais atuais disponíveis nas tecnologias R e Python foram testados e aplicados. A programação no R foi dominante e abarcou as fases de leitura, preparação e pré-processamento dos arquivos de texto, presentes nos capítulos de 3 a 6, bem como as atividades de proposição de modelos, produção de resultados e análises, referentes aos capítulos 4, 5 e 6. Os principais pacotes do PLN utilizados no R foram o **tm**, **qdap** e **tydiverse**. A programação Python se concentrou nas técnicas de aprendizagem de máquina supervisionada, onde merece destaque o pacote **sklearn** (*scikit-learn*).

- (ii) a estruturação de base textual (*corpora*) dos discursos parlamentares compreendendo as legislaturas de número 51, 52, 53, 54 e 55;

O Capítulo 3 foi dedicado à estruturação do *corpora* de textos do discurso parlamentar para as legislaturas definidas. Foram compilados e organizados 345.217 discursos.

- (iii) a disponibilização dos dados, scripts de programação e resultados em repositório público com a finalidade de incentivar novos estudos sobre o tema e de prover meios para a reprodutibilidade da pesquisa;

Todos os scripts e resultados podem ser reproduzidos e estão organizados em pastas correspondentes às etapas de execução desta pesquisa, disponíveis no repositório público <https://github.com/Cefor/DiscursoDeputados>.

Objetivos de caráter analítico:

- (iv) a construção dos sintagmas, ou n-gramas, com grupos de duas palavras e validação de *collocations*;

Os sintagmas de palavras individuais (unigramas) e de agrupamento de duas palavras (bigramas) foram gerados de acordo com os procedimentos de tokenização, apresentados no Capítulo 4, e armazenados em arquivos do tipo “corpus_partido_ini_fim_limpo.rds” para os anos de 2001 a 2017. No Capítulo 5, os bigramas foram avaliados quanto à dependência das respectivas palavras formadoras, no intuito de verificar se a composição constituía uma forma convencional de dizer as coisas (*collocations*), ou se aconteciam ao acaso. Esse teste foi incorporado aos algoritmos de comparação dos discursos.

- (v) a identificação de padrões do discurso, análise de convergência ideológica e posicionamento político-partidário na linha do tempo;

As investigações iniciais com o intuito de identificar padrões do discurso se deram por inspeção visual das nuvens de palavras, gráficos de frequência, dendogramas e modelo de tópicos, que revelaram, basicamente, as principais temáticas discutidas na Câmara dos Deputados a cada ano do período. Essa visão contribui para a compreensão de como evoluíram, ao longo dos anos, os assuntos que receberam destaque no Parlamento. Muito embora esses recursos sejam úteis para aguçar as intuições, não foram suficientes para se confirmar identidade ideológica nos textos do discurso.

Nesse sentido, a pesquisa avançou na comparação dos discursos por meio de modelos probabilísticos, donde surgiu a ideia de se construir o Índice de Identidade Ideológica, baseado na estatística χ^2 , que se mostrou útil na avaliação do comportamento de grupos de partidos quanto à convergência ideológica, em especial, no caso das coalizões governamentais. Esse indicador possibilitou observar as variações desse comportamento na linha do tempo, com potencial explicativo dos fatos políticos relevantes de cada época.

- (vi) a identificação de grupos por meio da aplicação de classificadores e técnicas de aprendizagem de máquina.

A identificação de grupos de forma não supervisionada se deu por meio da técnica de clusterização e do modelo de tópicos LDA, métodos clássicos no processamento de textos com PLN, apresentados no Capítulo 4, que contribuem para o conhecimento do conteúdo dos discursos e para a classificação de documentos. No Capítulo 6, a aprendizagem de máquina supervisionada se baseou no modelo multinomial de Naive Bayes para classificar discursos nos rótulos PT e PSDB, com acurácia de 70% de acertos. Também foi realizado ensaio do modelo de Naive Bayes como técnica de aferição da similaridade dos discursos para identificação ideológica, com resultados menos sensíveis que os produzidos pelo modelo qui-quadrado.

Diante do exposto, conclui-se que a expectativa inicial de que as técnicas do PLN contribuiriam para organizar, classificar, recuperar e divulgar o conhecimento implícito da atividade política contida no discurso parlamentar se confirmou.

Uma importante contribuição que se deixa como legado é, sem dúvida, o Índice de Identidade Ideológica que constitui ferramenta objetiva de análise do discurso, podendo ser usada, também, como parâmetro de comparação entre estudos.

Contudo, talvez a principal contribuição deste trabalho seja a de abrir mais um caminho para que o PLN e outros métodos quantitativos se consolidem como técnicas de análise do discurso parlamentar proferido no Congresso Brasileiro. Em campo repleto de incertezas, como o da Ciência Política, novos rumos são sempre bem-vindos à elucidação de questões.

Trabalhos futuros poderiam dedicar esforços na classificação dos discursos tendo como foco o parlamentar. Esse processo teria potencial para revelar a assinatura de discurso de cada orador, vocabulários e estilos próprios, contradições e outras características que, devidamente organizadas, serviriam como instrumento de acompanhamento da atuação parlamentar.

Outra possibilidade é a confrontação de padrões de votação da coalização governista e de outros agrupamentos partidários com o Indicador de Identidade Ideológica, de forma a verificar se essas diferentes abordagens apontam para conclusões similares.

Poder-se-ia pensar, ainda, em modelos baseados em dicionário léxico, capazes de analisar textos do discurso e de polarizar as palavras de acordo com os sentimentos por elas transmitidos.

Enfim, as possibilidades de novos estudos são diversas e aqui se podem encontrar alguns dos passos fundamentais, orientadores para saltos maiores.

REFERÊNCIAS BIBLIOGRÁFICAS

- AGRAWAL, Amritanshu; FU, Wei; MENZIES, Tim. What is Wrong with Topic Modeling? (and How to Fix it Using Search-based Software Engineering). **Information and Software Technology Journal**, Carolina do Norte, fev. 2018. Disponível em: <<https://arxiv.org/abs/1608.08176>>. Acesso em: 5 jan.2018.
- ARANHA, Christian; PASSOS, Emmanuel. Tecnologia de Mineração de Textos. **Revista Eletrônica de Sistemas de Informação**, Rio de Janeiro, v. 5, n. 2, 2006. Disponível em: <<http://www.periodicosibepes.org.br/index.php/reinfo/article/view/171>>. Acesso em: 10 jan. 2018.
- AXELROD, Robert M. **Conflict of interest: a theory of divergent goals with applications to politics**. Chicago: Markham Pub. Co, 1970.
- BEZERRA, Gabriella Maria Lima. A Oposição nos Governos FHC e LULA: um balanço da atuação parlamentar na Câmara dos Deputados. 2012. **Dissertação (Mestrado em Ciências Políticas)**, Universidade Federal do Rio Grande do Sul, Porto Alegre.
- BLEI, David M.; NG, Andrew Y.; JORDAN., Michael I. Latent Dirichlet Allocation. **Journal of Machine Learning Research**, Cambridge, v. 3, p. 993-1022, jan. 2003.
- BRASIL. Câmara dos Deputados. **Regimento interno, estabelecido pela resolução n.18, de 2017**. Disponível em: <<http://bd.camara.gov.br/bd/handle/bdcamara/18847>>. Acesso em 04 de janeiro de 2018.
- CANCIAN, Renato. Ideologia: Termo tem vários significados em ciências sociais. **UOL EDUCAÇÃO - Página 3 Pedagogia**, [S.L], mai. 2007. Disponível em: <<https://educacao.uol.com.br/disciplinas/sociologia/ideologia-termo-tem-varios-significados-em-ciencias-sociais.htm>>. Acesso em: 11 jan. 2018.
- COMPARATIVE AGENDAS PROJECT. **Comparing policies worldwide**. Disponível em: <<http://www.policyagendas.org>>. Acesso em: 22 jan. 2018.
- CONGRESSIONAL BILLS PROJECT. **Welcome to the congressional bills project**. Disponível em: <<http://www.congressionalbills.org>>. Acesso em: 15 jan. 2018.
- COVINGTON, Michael A.; NUTE, Donald; VELLINO, Andre. **Prolog programming in depth: Artificial intelligence programs**. Georgia: Prentice Hall, 1996. 516 p.
- EAGLETON, Terry. **Ideologia: uma introdução**. São Paulo: Boitempo, 1997.
- EVERT, Stefan; KRENN, Brigitte. Using small random samples for the manual evaluation of statistical association measures. **Computer Speech**, Londres, v. 19, n. 4, p. 450-466, out. 2005.



- FALCÃO, Sérgio Dagnino. Proposição, aplicação e avaliação de um método de classificação temática em bases de dados textuais indexadas com auxílio de vocabulários controlados. 2003. **Dissertação (Mestrado em Gestão do Conhecimento e Tecnologia da Informação)**, Universidade Católica de Brasília, Brasília.
- FAYYAD, Usama M. Data mining and knowledge discovery: making sense out of data. **IEEE Journals**, [S.L], v. 11, n. 5, p. 20-25, out. 1996.
- FEINERER, Ingo; HORNIK, Kurt; MEYER, David. Text Mining Infrastructure in R. **Journal of Statistical Software**, Boston, v. 25, n. 5, mar. 2008.
- FERREIRA, Aurélio Buarque H. **Mini aurélio século xxi: o minidicionário da Língua Portuguesa**. 4 ed. Rio de Janeiro: Nova Fronteira, 2001.
- GNERRE, Maurício. **Linguagem, escrita e poder**. 3 ed. São Paulo: Martins Fontes Editora Ltda., 1991.
- GRIMMER, Justin. A Bayesian Hierarchical Topic Model for Political Texts: Measuring Expressed Agendas in Senate Press Releases. **Political Analysis**, Cambridge, v. 18, n. 1, p. 1-35, jan. 2010.
- GRIMMER, Justin; STEWART, Brandon M. Text as Data: The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts. **Political Analysis**, Oxford, v. 21, n. 3, p. 267-297, jan. 2013.
- HEARST, Marti A. Untangling text data mining. **Proceeding ACL '99 Proceedings of the 37th annual meeting of the Association for Computational Linguistics on Computational Linguistics**, Maryland, p. 3-10, jun. 1999.
- JURAFSKY, Daniel; MARTIN, James H. **Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition**. 2 ed. Nova Jersey: Prentice Hall, 2008.
- KILGARRIFF, Adam; ROSE, Tony. Measures for corpus similarity and homogeneity. **Information Technology Research Institute Technical Report Series**, Brighton, p. 46-52, jul. 1998
- KWARTLER, Ted. Text Mining: Bag of words. **DATA CAMP**. Disponível em: <<https://www.datacamp.com/courses/intro-to-text-mining-bag-of-words>>. Acesso em: 23 jan. 2018.
- LAYMAN, Lucas; NIKORA, Allen P.; MEEK, Joshua. Topic modeling of nasa space system problem reports: research in practice, in. **2016 IEEE/ACM 13th Working Conference on Mining Software Repositories (MSR)**, Austin, p. 303-314, mai. 2016.
- MACHADO, A. P. et al. MINERAÇÃO DE TEXTO EM REDES SOCIAIS APLICADA À EDUCAÇÃO A DISTÂNCIA. **Revista Digital da CVA - Ricesu**, [S.L], v. 6, n. 23, jul. 2010.

- MANNING, Christopher; SCHÜTZE, Hinrich. **Foundations of statistical natural language processing**. Cambridge: The MIT Press, 1999.
- MARKHAM, Stephen K.; KOWOLENKO, Michael; MICHAELIS, Timothy L.. Unstructured Text Analytics to Support New Product Development Decision. **Research Technology Management**, Virginia, v. 58, n. 2, p. 30-38, mar./abr. 2015.
- MOREIRA, Davi Cordeiro. Com a palavra os nobres deputados: frequência e ênfase temática dos discursos dos parlamentares brasileiros. 2016. **Tese (Doutorado em Ciências Política) - Faculdade de Filosofia, Letras e Ciências Humanas, Universidade de São Paulo**, São Paulo.
- MURTAGH, Fionn; LEGENDRE, Pierre. Ward's Hierarchical Clustering Method: Clustering Criterion and Agglomerative Algorithm. **Journal of Classification**, New York, v. 31, n. 3, p. 274-295, out. 2014.
- NETO, Aristides Coelho. **Além da revisão: critérios para revisão textual**. 2 ed. Brasília: Senac Distrito Federal, 2008.
- PAIVA, Cláudia Gomes. Discurso parlamentar: uma proposta de sistematização. **Cadernos Aslegis - II Seminário Internacional Assessoramento Institucional no Poder Legislativo**, Brasília, v. 8, n. 30, p. 83-127, jan./abr. 2007.
- PEDERSEN, Ted. et al. **The Ngram Statistics Package**. 2015. Disponível em: <<http://www.d.umn.edu/~tpederse/nsp.html>>. Acesso em: 15 jan. 2018
- PEDREGOSA, F. et al. Machine Learning in Python. **Journal of Machine Learning Research**, [S.L], v. 12, n. 2011, p. 2825-2830, out. 2011.
- QUINN, K. M. et al. How to Analyze Political Attention with Minimal Assumptions and Costs. **American Journal of Political Science**, Michigan, v. 54, n. 1, p. 209-228, jan. 2010.
- REISMAN, Leonardo Socha. Coalizões, partidos e programas de governo: a submissão das bandeiras partidárias ao mercado eleitoral. **Dissertação de Mestrado em Ciência Política**, Brasília, p. 98, set. 2016.
- RIKER, William H. **The theory of political coalitions**. Michigan: Yale University Press, 1962.
- RODRIGUES, Leôncio Martins. **Partidos, ideologia e composição social**: Um estudo das bancadas partidárias na câmara dos deputados. Rio de Janeiro: Centro Edelstein de Pesquisas Sociais, 2009.
- SAMUEL, Arthur Lee. Some Studies in Machine Learning Using the Game of Checkers. **IBM Journal of Research and Development**, Nova Jersey, v. 3, n. 3, p. 210 - 229, jul. 1959.

- SANTOS, R. E. S. et al. Técnicas de processamento de linguagem natural aplicadas ao processo de mineração de textos: resultados preliminares de um mapeamento sistemático. **Revista de Sistemas e Computação**, Salvador, v. 4, n. 2, p. 116-125, jul./dez. 2014.
- SILVA, Edson Marchetti Da; SOUZA, Renato Rocha. Fundamentos em processamento de linguagem natural: uma proposta para extração de bigramas. **Encontros Bibli: revista eletrônica de biblioteconomia e ciência da informação**, Florianópolis, v. 19, n. 40, p. 1-32, mai./ago. 2014.
- SOUZA, Joel Martins De. Revisão de Discurso Parlamentar no Departamento de Taquigrafia da Câmara dos Deputados. 2009.118 f. **Dissertação (Especialização em Processo Legislativo)**, Centro de Formação, Treinamento e Aperfeiçoamento da Câmara dos Deputados, Brasília.
- SPIRLING, Arthur. US Treaty-making with American Indians. **American Journal of Political Science**, Michigan, v. 56, n. 1, p. 84-97, dez. 2011.
- TOLEDO, C. M. et al. Automatic classification of written descriptions by healthy adults: An overview of the application of natural language processing and machine learning techniques to clinical discourse analysis. **Dement Neuropsychol**, São Paulo, v. 8, n. 3, p. 227-235, set. 2014.
- VILLAVICENCIO, A. et al. Identificação de expressões multipalavra em domínios específicos. **Linguamática**, Portugal, v. 2, n. 1, p. 15-34, abr. 2010.
- WANG, Lijuan; LIU, Rong. Rapid Method to Extract Multiword Expressions with Statistic Measures and Linguistic Rules. **Web Information Systems and Mining**, Berlin, p. 234-241, 2011.
- WICKHAM, Hadley. Tidy Data. **Journal of Statistical Software**, Innsbruck, v. 59, n. 10, p. 1-23, ago. 2014.
- YOUNG, Lori; SOROKA, Stuart. Affective News: The Automated Coding of Sentiment in Political Texts. **Political Communication**, Washington, v. 29, n. 2, p. 205-231, abr. 2012.
- ZHANG, W. et al. Improving effectiveness of mutual information for substantival multiword expression extraction. **Expert Systems with Applications**, [S.L], v. 36, n. 8, p. 10919-10930, out. 2009.

ANEXOS

ANEXO A – ATESTE DE ATIVIDADES - MARÇO/ABRIL DE 2017



Brasília, 28 de abril de 2017.



DECLARAÇÃO DE ATIVIDADES

Declaro, para os devidos fins, que FABIANO PERUZZO SCHWARTZ, pesquisador em estágio pós-doutoral neste Departamento de Engenharia Elétrica da Universidade de Brasília, desenvolveu, no período de 01/03/2017 a 28/04/2017, as atividades de pesquisa a seguir relacionadas:

ATIVIDADE	CARGA HORÁRIA
Instalação do ambiente R, da ferramenta RStudio e dos pacotes de funções necessários ao processamento de arquivos XML.	5 horas
Desenvolvimento de rotinas, na linguagem R, para carga da lista dos discursos proferidos por deputados em Plenário durante as legislaturas 52, 53, 54 e 55.	15 horas
Carga da lista de discursos das legislaturas 52, 53, 54 e 55.	10 horas
Desenvolvimento de rotinas, na linguagem R, para carga do inteiro teor dos discursos proferidos por deputados em Plenário durante as legislaturas 52, 53, 54 e 55.	20 horas
Carga do inteiro teor dos discursos das legislaturas 52, 53, 54 e 55.	15 horas
Verificação de integridade e ajuste dos arquivos em formato CSV.	15 horas
Desenvolvimento de rotinas, na linguagem R, para ajuste do tamanho dos textos de inteiro teor para o limite de tamanho permitido a strings.	15 horas
Desenvolvimento de funções para a codificação txt-Base64 e decodificação Base64-txt.	5 horas
Criação de repositório público para o armazenamento das rotinas de programação e dos dados. https://github.com/Fpschwartz1/DiscursoDeputados	10 horas
Total	110 horas


Francisco Assis de Oliveira Nascimento – Professor Titular
Coordenador do Grupo de Processamento Digital de Sinais – GPDS
Departamento de Engenharia Elétrica – ENE
Faculdade de Tecnologia – FT
Universidade de Brasília – UnB

ANEXO B – ATESTE DE ATIVIDADES - MAIO/JUNHO DE 2017




Brasília, 30 de junho de 2017.



DECLARAÇÃO DE ATIVIDADES

Declaro, para os devidos fins, que FABIANO PERUZZO SCHWARTZ, pesquisador em estágio pós-doutoral neste Departamento de Engenharia Elétrica da Universidade de Brasília, desenvolveu, no período de 01/05/2017 a 30/06/2017, as atividades de pesquisa a seguir relacionadas:

ATIVIDADE	CARGA HORÁRIA
Script R para retirada dos metadados de formatação do texto e aplicação nos arquivos de discurso inteiro teor.	10 horas
Script R para remoção de quadros, tabelas e figuras inseridas no discurso.	10 horas
Script R para a criação do corpus (dados do mundo real empregando linguagem como a que ocorre na fala ou escrita corrente) a partir dos textos do discurso parlamentar dos anos de 2003 a 2017.	10 horas
Instalação da plataforma aberta Anaconda, para análise de dados, e preparação do ambiente virtual Python 3.6, com o pacote de processamento de linguagem natural NLTK 3.	10 horas
Scripts Python no ambiente Jupyter Notebook para teste de desempenho de carga do corpus (2003 a 2017), tokenização e preparação do texto para processamento de linguagem com o pacote NLTK.	10 horas
Scripts Python para organização dos n-gramas (bi, tri e tetragramas) e cômputo da frequência.	10 horas
Testes dos recursos dos subpacotes de PLN do pacote NLTK: corpus, tokenize, probability e collocations.	10 horas
Script preditor de palavras.	10 horas
Total	80 horas


Francisco Assis de Oliveira Nascimento – Professor Titular
Coordenador do Grupo de Processamento Digital de Sinais – GPDS
Departamento de Engenharia Elétrica – ENE
Faculdade de Tecnologia – FT
Universidade de Brasília – UnB

ANEXO C – ATESTE DE ATIVIDADES - JULHO/AGOSTO DE 2017



Brasília, 1 de setembro de 2017.



DECLARAÇÃO DE ATIVIDADES

Declaro, para os devidos fins, que FABIANO PERUZZO SCHWARTZ, pesquisador em estágio pós-doutoral neste Departamento de Engenharia Elétrica da Universidade de Brasília, desenvolveu, no período de 01/07/2017 a 31/08/2017, as atividades de pesquisa a seguir relacionadas:

ATIVIDADE	CARGA HORÁRIA
Unificação dos arquivos do discurso e conversão para o formato RDS.	5 horas
Criação de corpus específico por meio da informação de critérios de período, tipo da sessão e partido político.	10 horas
Conversão do texto utilizando funções de origem para manipulação por vetores.	5 horas
Limpeza do corpus: transformações para minúscula, remoção de números, remoção de pontuação e de espaços.	5 horas
Criação de dicionário de <i>stopwords</i> com 166 palavras específicas do discurso parlamentar.	10 horas
Criação de dicionário de <i>stopwords</i> com nomes próprios encontrados no discurso parlamentar.	5 horas
Criação da matriz de frequência de termos e documentos; identificação das palavras mais frequentes; penalização de palavras por meio do algoritmo inversão da frequência de documentos; filtragem dos termos escassos (<i>sparsity</i>)	15 horas
Criação de nuvens de palavras frequentes e comparação das variações de vocabulário entre PT e PSDB no período de 2003 a 2017.	20 horas
Atualização do repositório público no Github.	5 horas
Total	80 horas

Francisco Assis de Oliveira Nascimento – Professor Titular
Coordenador do Grupo de Processamento Digital de Sinais – GPDS
Departamento de Engenharia Elétrica – ENE
Faculdade de Tecnologia – FT
Universidade de Brasília – UnB

ANEXO D – ATESTE DE ATIVIDADES - SETEMBRO/NOVEMBRO DE 2017




Brasília, 30 de novembro de 2017.


DECLARAÇÃO DE ATIVIDADES

Declaro, para os devidos fins, que FABIANO PERUZZO SCHWARTZ, pesquisador em estágio pós-doutoral neste Departamento de Engenharia Elétrica da Universidade de Brasília, desenvolveu, no período de 01/09/2017 a 30/11/2017, as atividades de pesquisa a seguir relacionadas:

ATIVIDADE	CARGA HORÁRIA
Implementação e testes da função remove_plural para a remoção dos plurais no procedimento de limpeza do <i>corpora</i> .	20 horas
Adequação das <i>stopwords</i> , com remoção dos plurais, e criação de dicionário de <i>stopwords</i> próprias do discurso parlamentar, de nomes dos membros da Mesa Diretora nas legislaturas 51, 52, 53, 54 e 55, de nomes compostos e nomes simples para a limpeza do <i>corpora</i> .	30 horas
Criação de script R para a geração de <i>corpus</i> ano-a-ano, por partido, e execução para os partidos PT e PSDB no período de 2001 a 2017.	15 horas
Análise de cluster hierárquica usando o conjunto de diferenças para os objetos em cluster e a fórmula de atualização de dissimilaridade de Lance-Williams, de acordo com o método <i>complete linkage</i> que encontra clusters similares.	20 horas
Identificação de tópicos nos <i>corpus</i> gerados para o PT e PSDB, para os anos de 2001 a 2017, por meio do algoritmo de alocação latente de Dirichlet (Latent Dirichlet Allocation - LDA) e modelos relacionados.	20 horas
Análise dos tópicos, no tempo, por partido.	20 horas
Atualização do repositório público no Github.	5 horas
Total	130 horas


Francisco Assis de Oliveira Nascimento – Professor Titular
Coordenador do Grupo de Processamento Digital de Sinais – GPDS
Departamento de Engenharia Elétrica – ENE
Faculdade de Tecnologia – FT
Universidade de Brasília – UnB

ANEXO E – ATESTE DE ATIVIDADES - DEZEMBRO DE 2017 A FEVEREIRO DE 2018



Brasília, 28 de fevereiro de 2018.

DECLARAÇÃO DE ATIVIDADES

Declaro, para os devidos fins, que FABIANO PERUZZO SCHWARTZ, pesquisador em estágio pós-doutoral neste Departamento de Engenharia Elétrica da Universidade de Brasília, desenvolveu, no período de 01/12/2017 a 28/02/2018, as atividades de pesquisa a seguir relacionadas:

ATIVIDADE	CARGA HORÁRIA
Estudo da distribuição dos temas mais frequentes do discurso por meio de histogramas e gráficos de densidade de probabilidade.	20 horas
Desenvolvimento, em R, das funções para construção de tabelas de contingência de bigramas, para execução do teste qui-quadrado sobre tabelas de contingência e para o teste de similaridade de <i>corpus</i> pela estatística χ^2 .	30 horas
Desenvolvimento, em R, dos scripts de teste de bigramas para a verificação de <i>collocations</i> .	20 horas
Desenvolvimento, em R, dos scripts de aferição de similaridade de <i>corpus</i> de textos do discurso parlamentar, por meio da criação de matrizes cruzadas de similaridade com todos os partidos.	40 horas
Desenvolvimento, em Python, dos scripts de aprendizagem de máquina supervisionada, baseada no modelo multinomial de Naive Bayes.	30 horas
Elaboração do relatório de pesquisa.	150 horas
Atualização do repositório público no Github.	10 horas
Total	300 horas

Francisco Assis de Oliveira Nascimento – Professor Titular
Coordenador do Grupo de Processamento Digital de Sinais – GPDS
Departamento de Engenharia Elétrica – ENE
Faculdade de Tecnologia – FT
Universidade de Brasília – UnB